Véhicules et émissions de CO_2

Prédire les émissions
Segmenter les profils

Catalogue automobile français, mars 2015

Le catalogue et son périmètre

20 824

variantes analysées

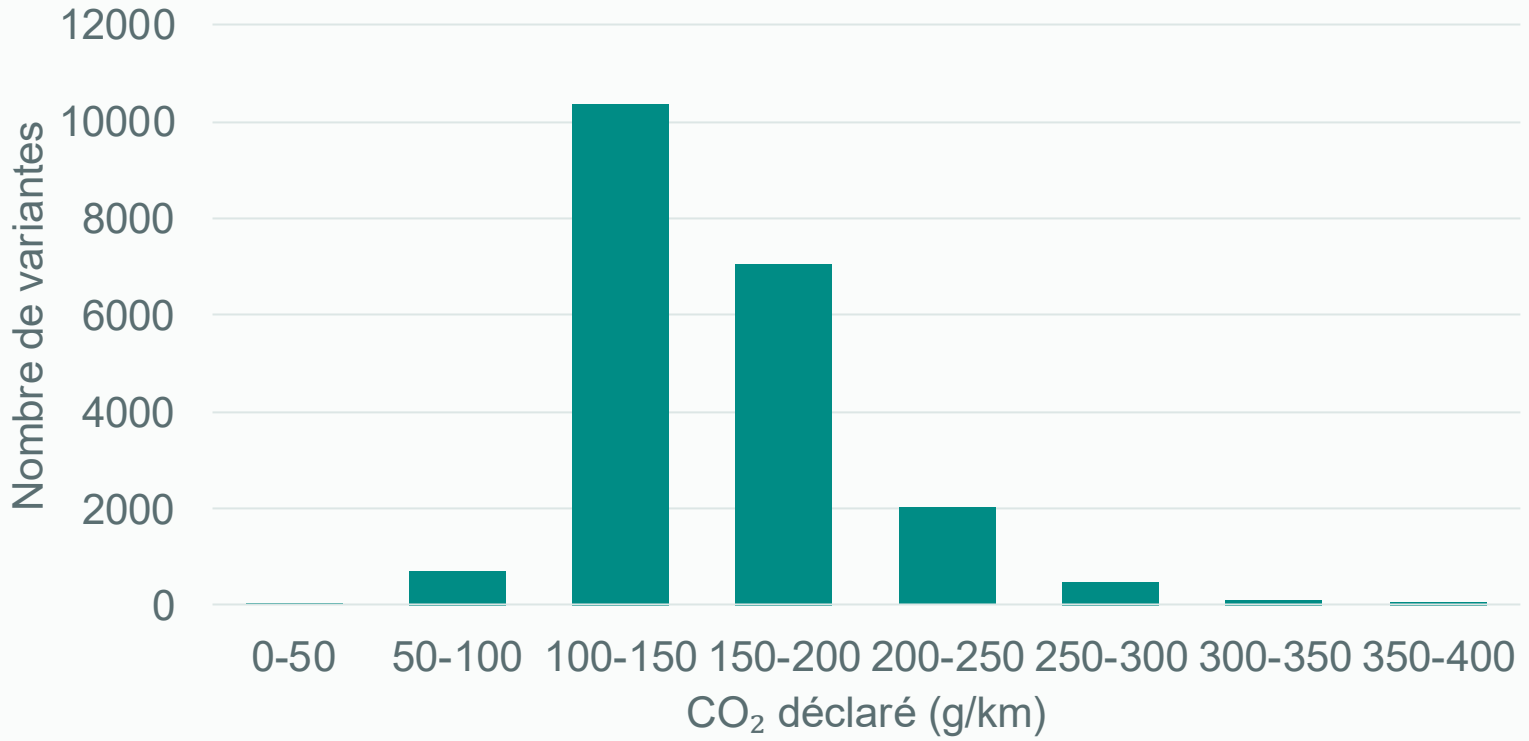
444

familles marque + modèle

Fichier brut	Jeu d’analyse	Hors périmètre
20 880 lignes	12 variables	56 lignes EL sans CO_2

Une variante de catalogue ne représente pas une part de marché

Des émissions et des familles très inégales



63,1 %

des lignes dans
10 familles

Médiane : 147 g/km. Les fréquences décrivent le catalogue

Les questions de l’étude

Observer les écarts d’émissions

Quelles caractéristiques les accompagnent ?

Estimer le CO_2 d’une autre famille

Quels profils techniques se ressemblent ?

Prédire le CO_2 de familles différentes

X Puissance, masse
Énergie, hybride, boîte

y CO_2 déclaré (g/km)

ENTRAÎNEMENT

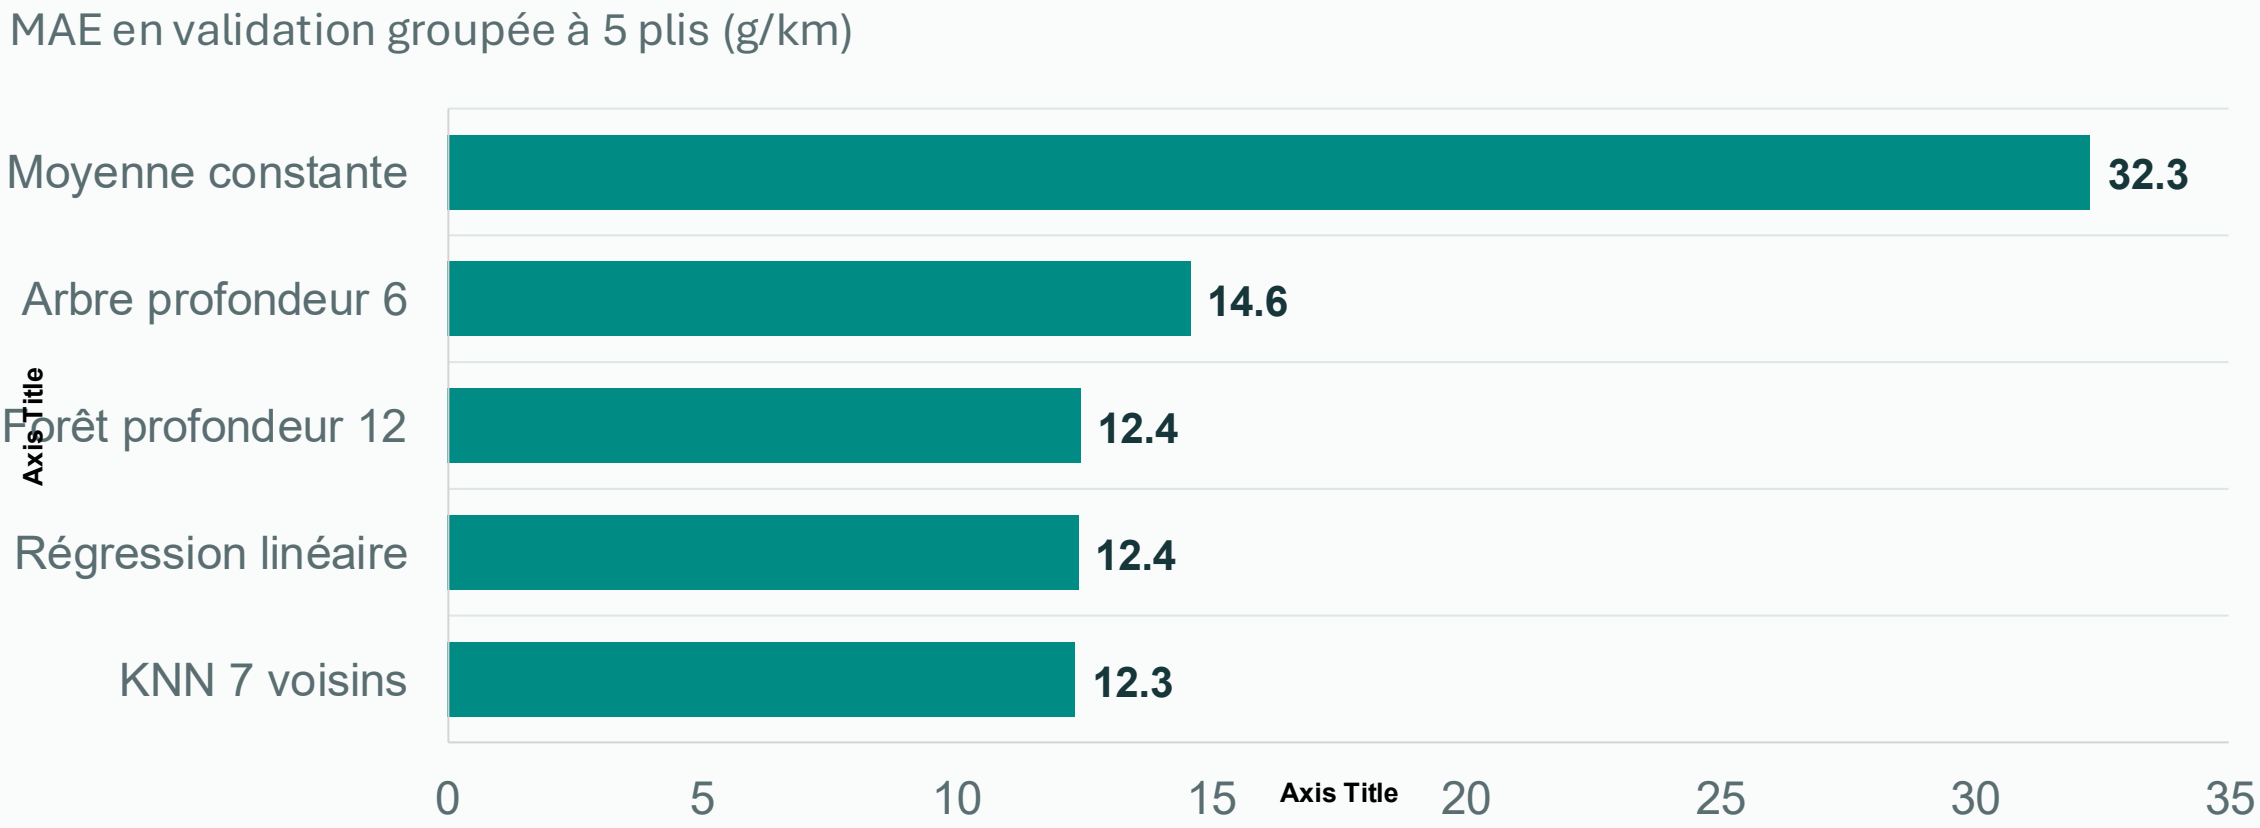
Validation groupée à 5 plis

TEST FAMILIAL

Familles distinctes

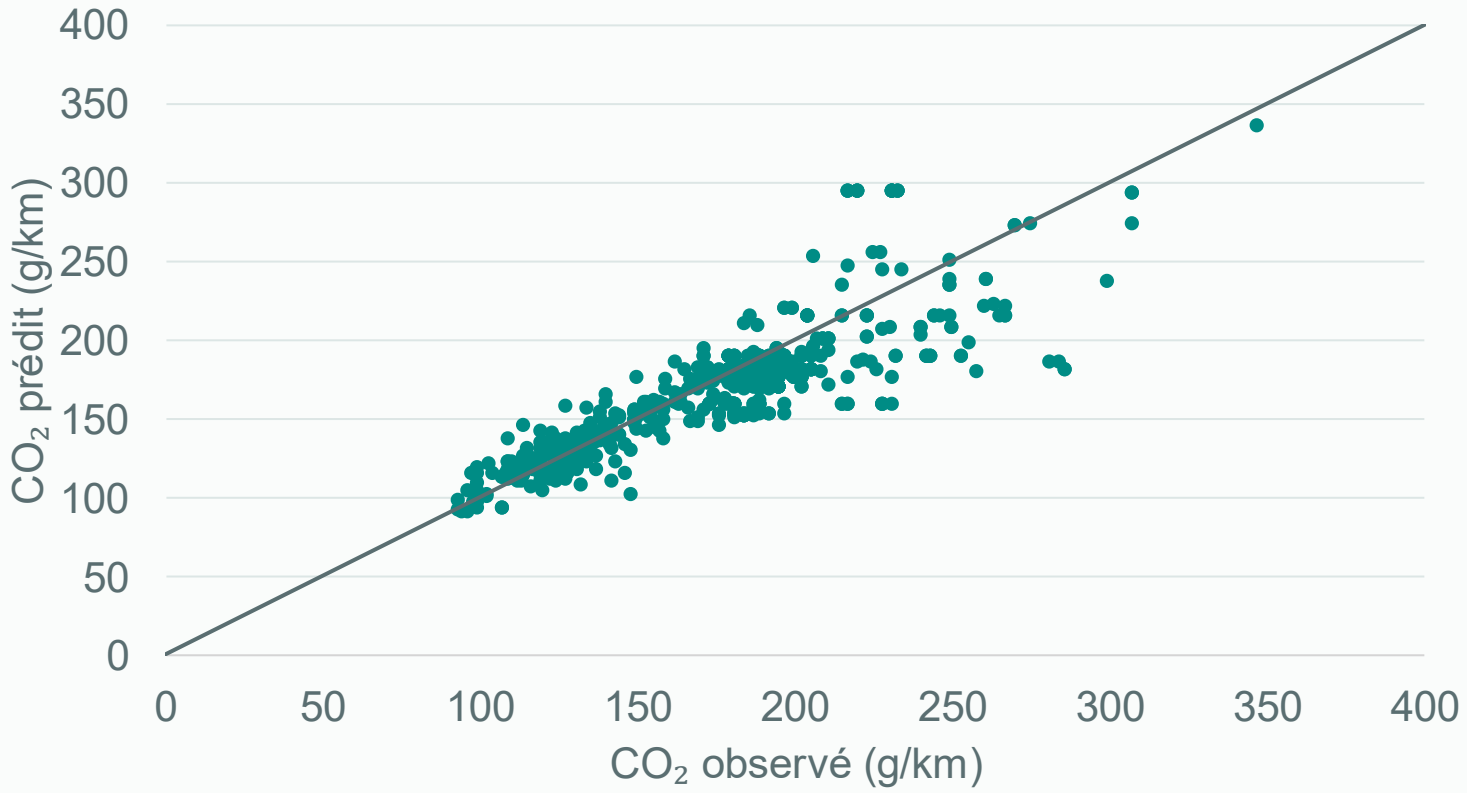
Régression : prédire une valeur

Comparer les modèles sur l’entraînement



Écarts < 0,10 g/km entre KNN, linéaire et forêt : quasi-égalité

La performance sur le test familial



16,8

MAE (g/km)

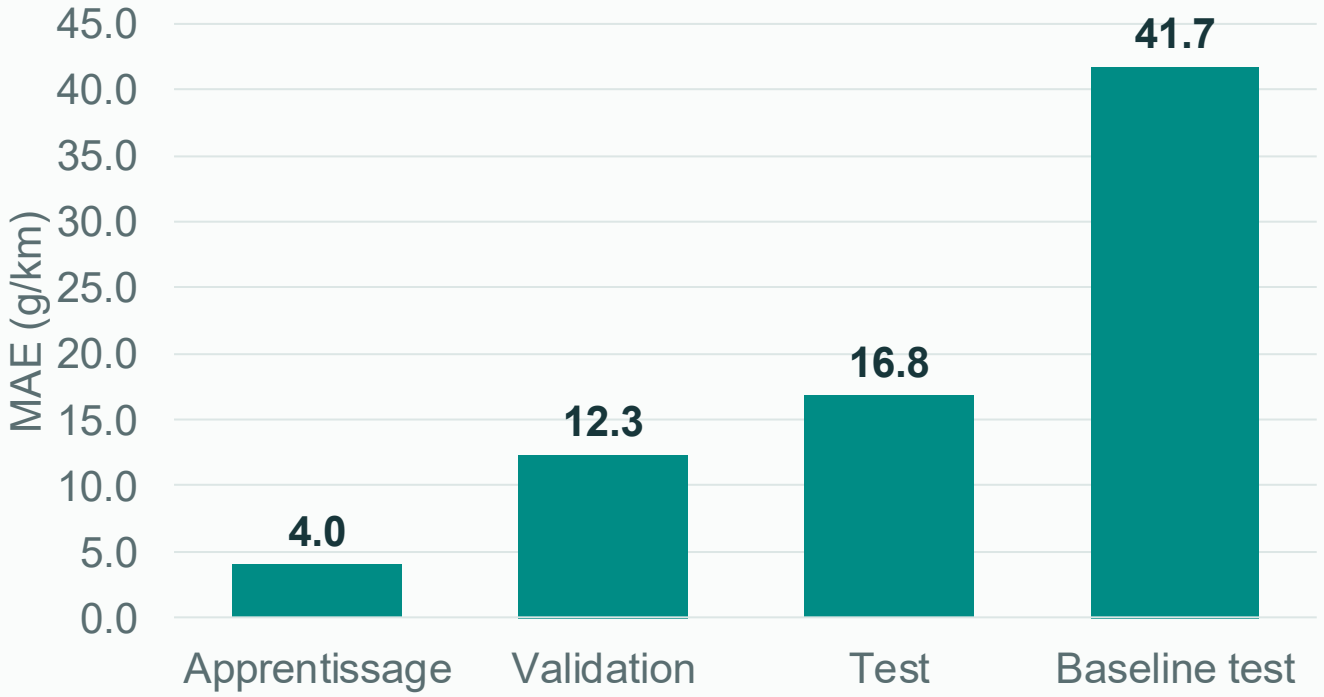
24,0

RMSE (g/km)

R^2 0,63

Test par famille : une évaluation de transfert au sein du catalogue

La portée de la généralisation



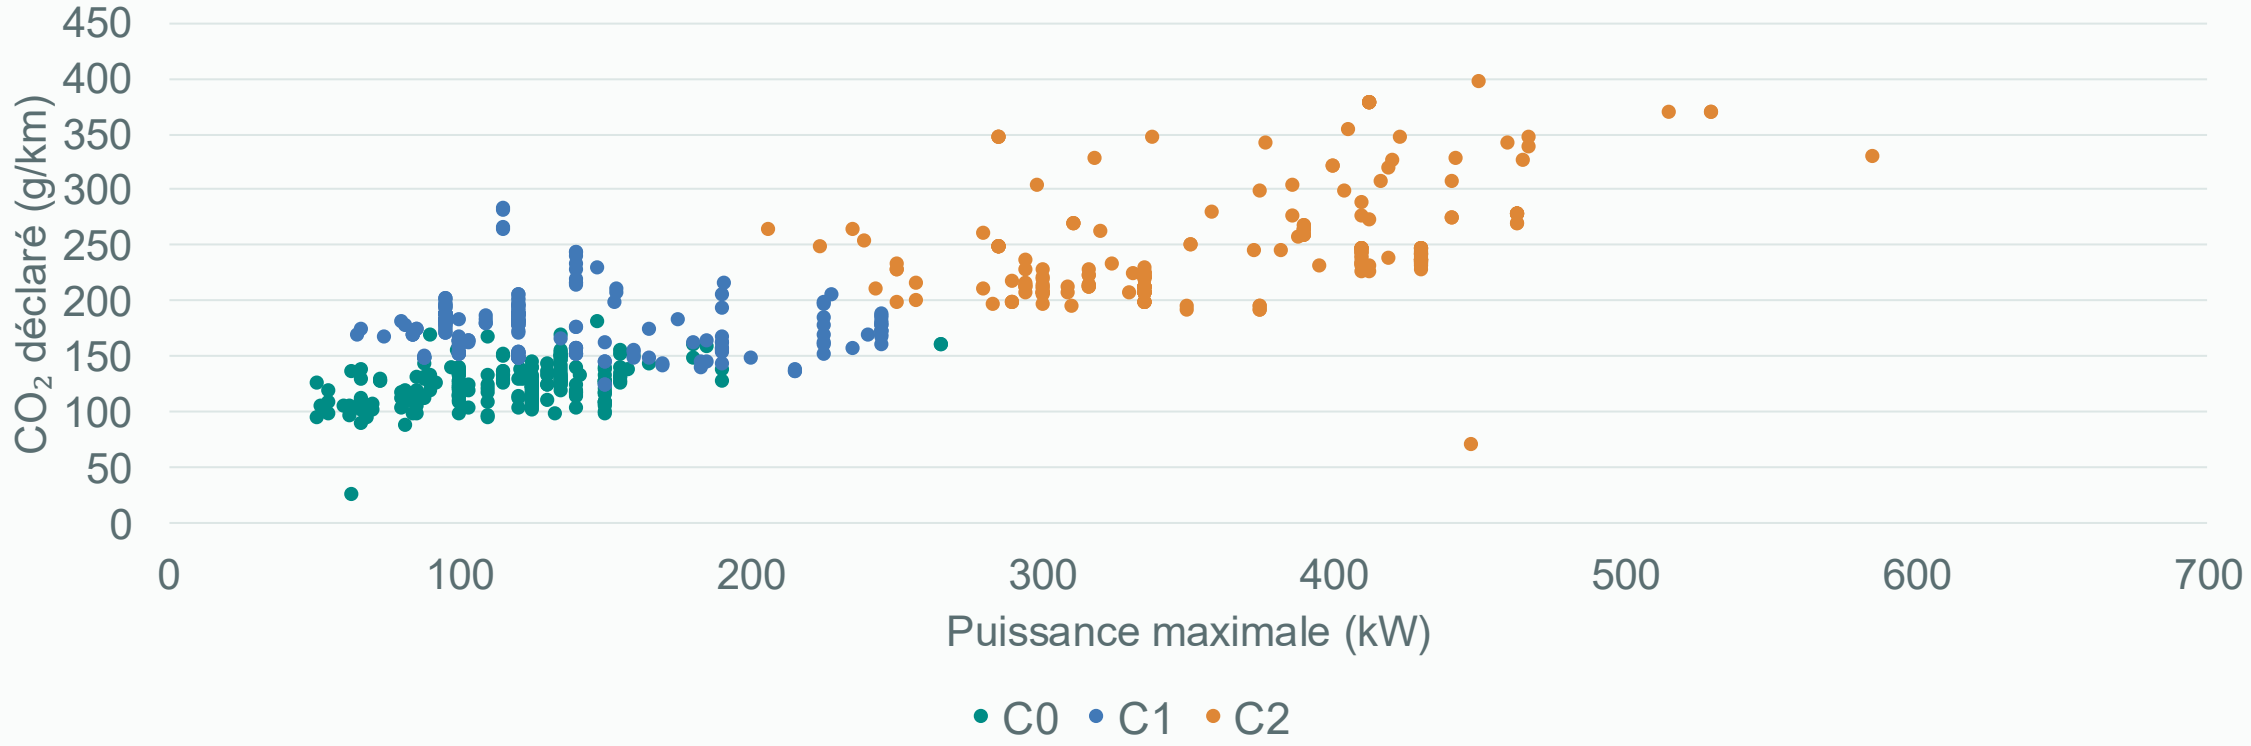
Puissance fiscale exclue

Lien historique
avec le CO_2

Audit rétrospectif. Une validation indépendante reste nécessaire

Segmenter les profils techniques

Échantillon équilibré : 220 points par groupe



Une proximité technique, à interpréter dans le contexte du catalogue

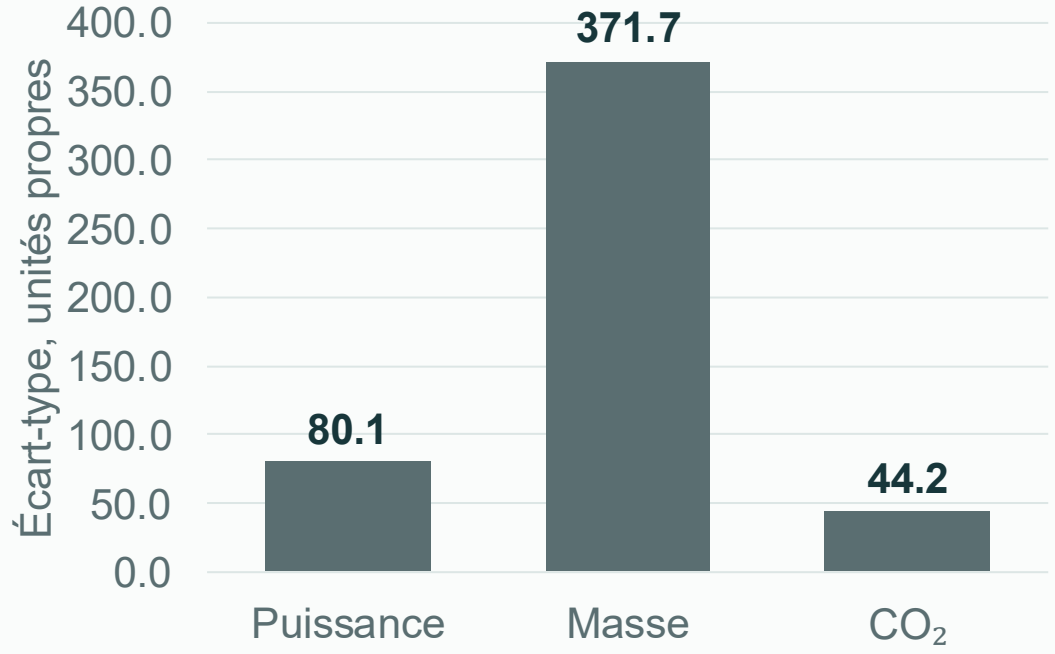
Le choix des variables

Variable retenue	Dimension décrite	Unité
Puissance maximale	Motorisation	kW
Masse minimale	Gabarit	kg
CO_2 mixte	Émissions déclarées	g/km

Consommation écartée : information très redondante avec le CO_2

L’effet de la standardisation

Standardiser : centrer et réduire





Chaque dimension contribue à la distance sur une échelle comparable

K-Means : groupes par proximité

Tirage équilibré : 220 points par groupe



Affecter

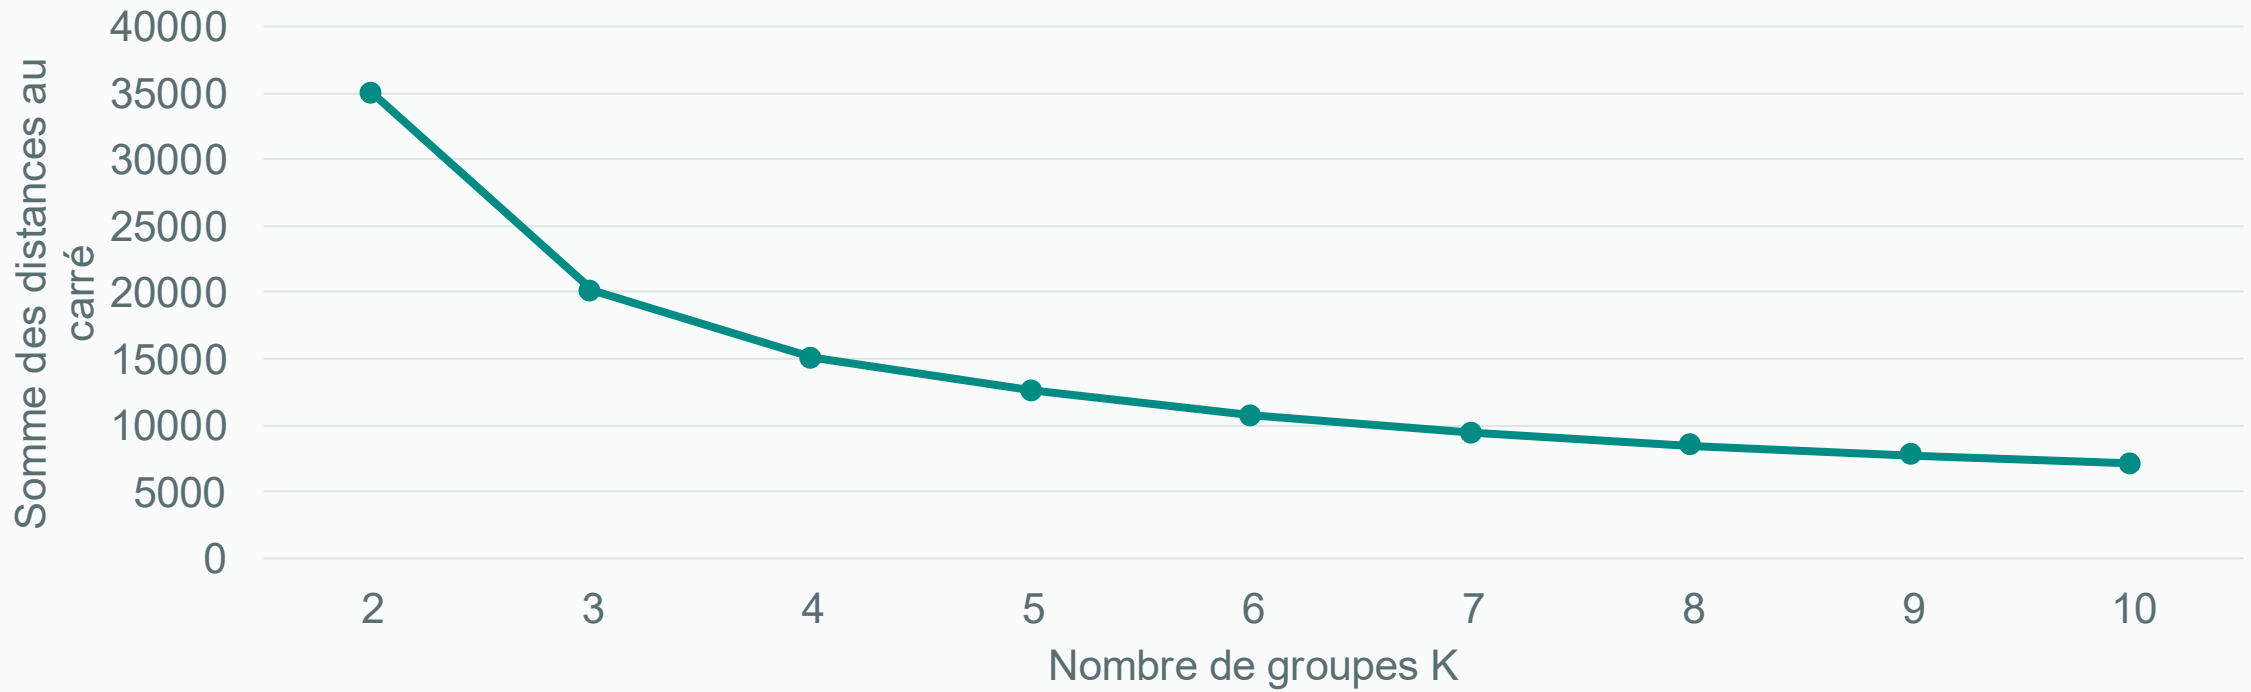
Recalculer

Répéter

Calcul dans trois dimensions. Les losanges indiquent les centres

La courbe du coude

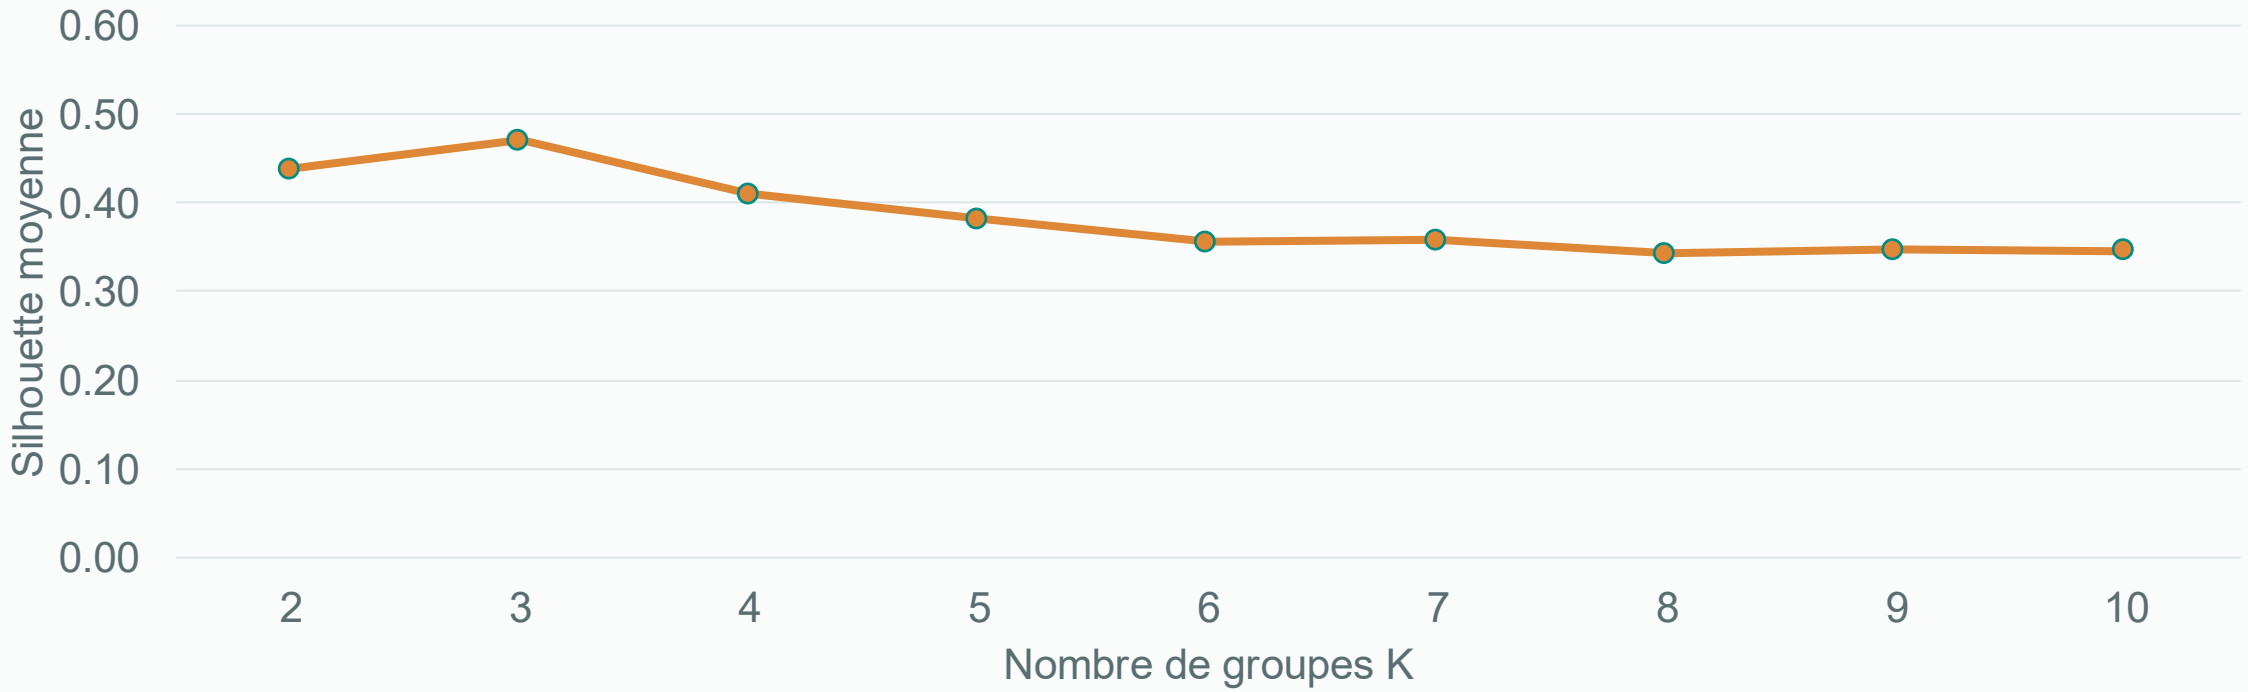
Inertie : dispersion à l'intérieur des groupes



K = 3 apporte un gain marqué, puis les gains ralentissent

Le score de silhouette

Silhouette : cohésion et séparation



K = 3 : silhouette 0,470 sur 5 000 observations

Les profils moyens des clusters

Profil	Variantes	Puissance (kW)	Masse (kg)	CO_2 (g/km)
C0	11 060	115,7	1 541	123,9
C1	7 963	139,2	2 147	176,9
C2	1 801	363,2	1 977	244,6

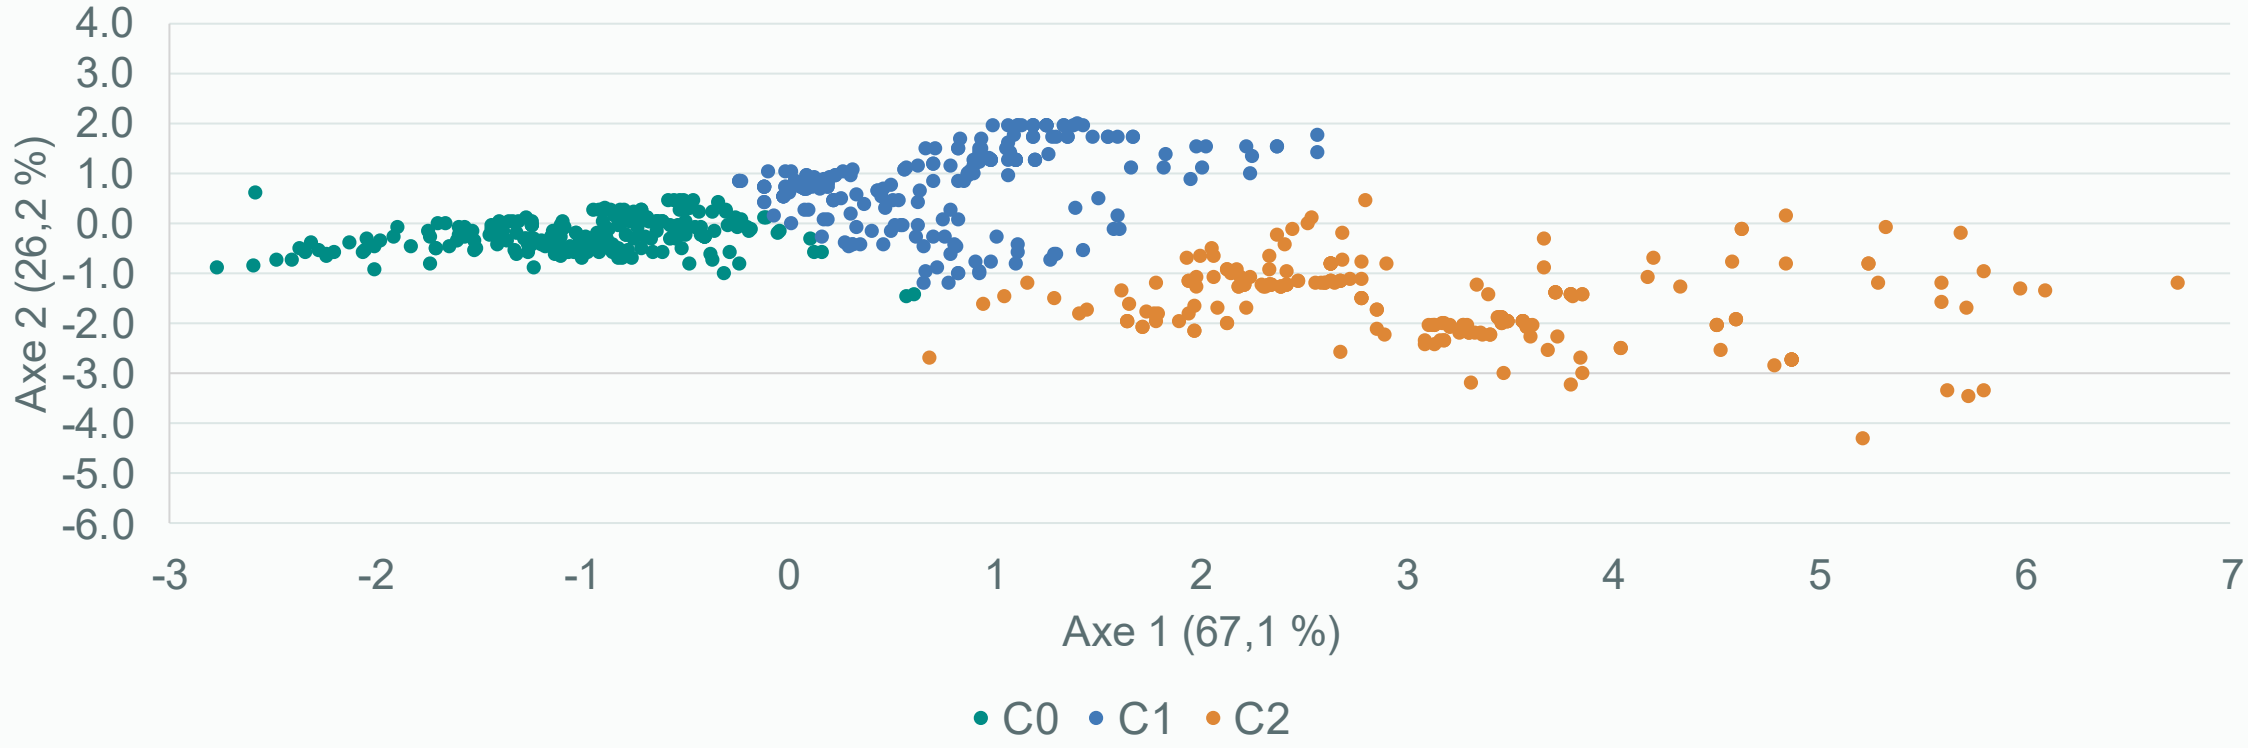
C0 : moins émetteurs **C1 : plus lourds** **C2 : plus puissants**

Les moyennes résument des distributions qui peuvent se chevaucher

Une vue des clusters en deux dimensions

ACP : projection synthétique

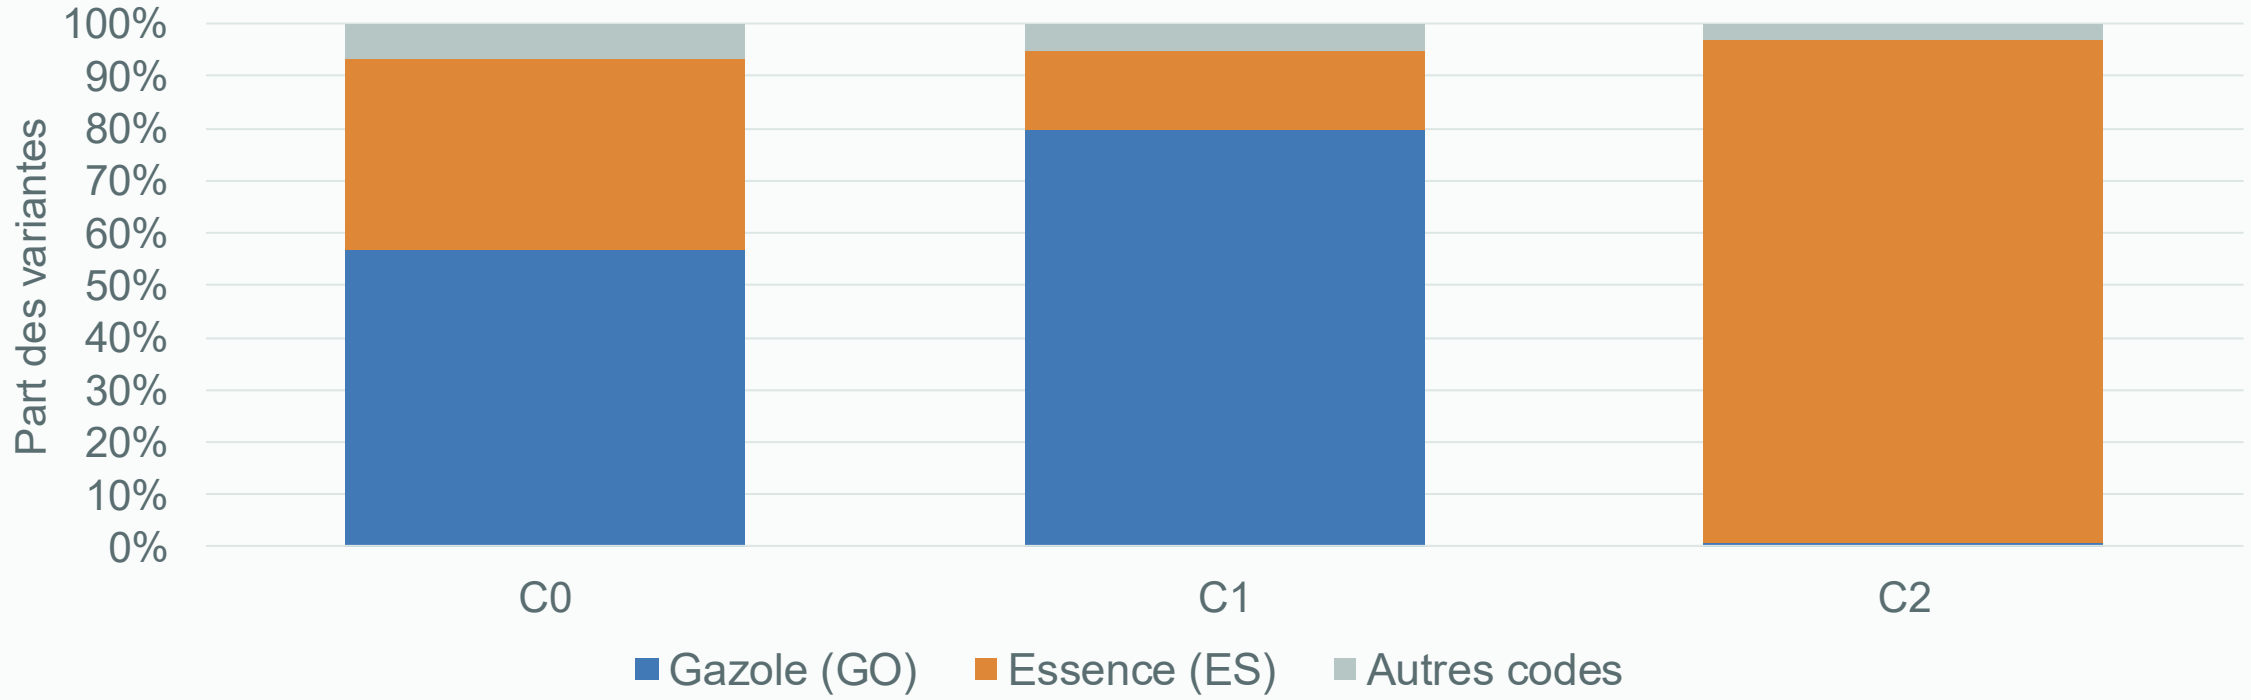
Tirage équilibré : 220 / groupe



93,3 % de variance conservée. La projection reste descriptive

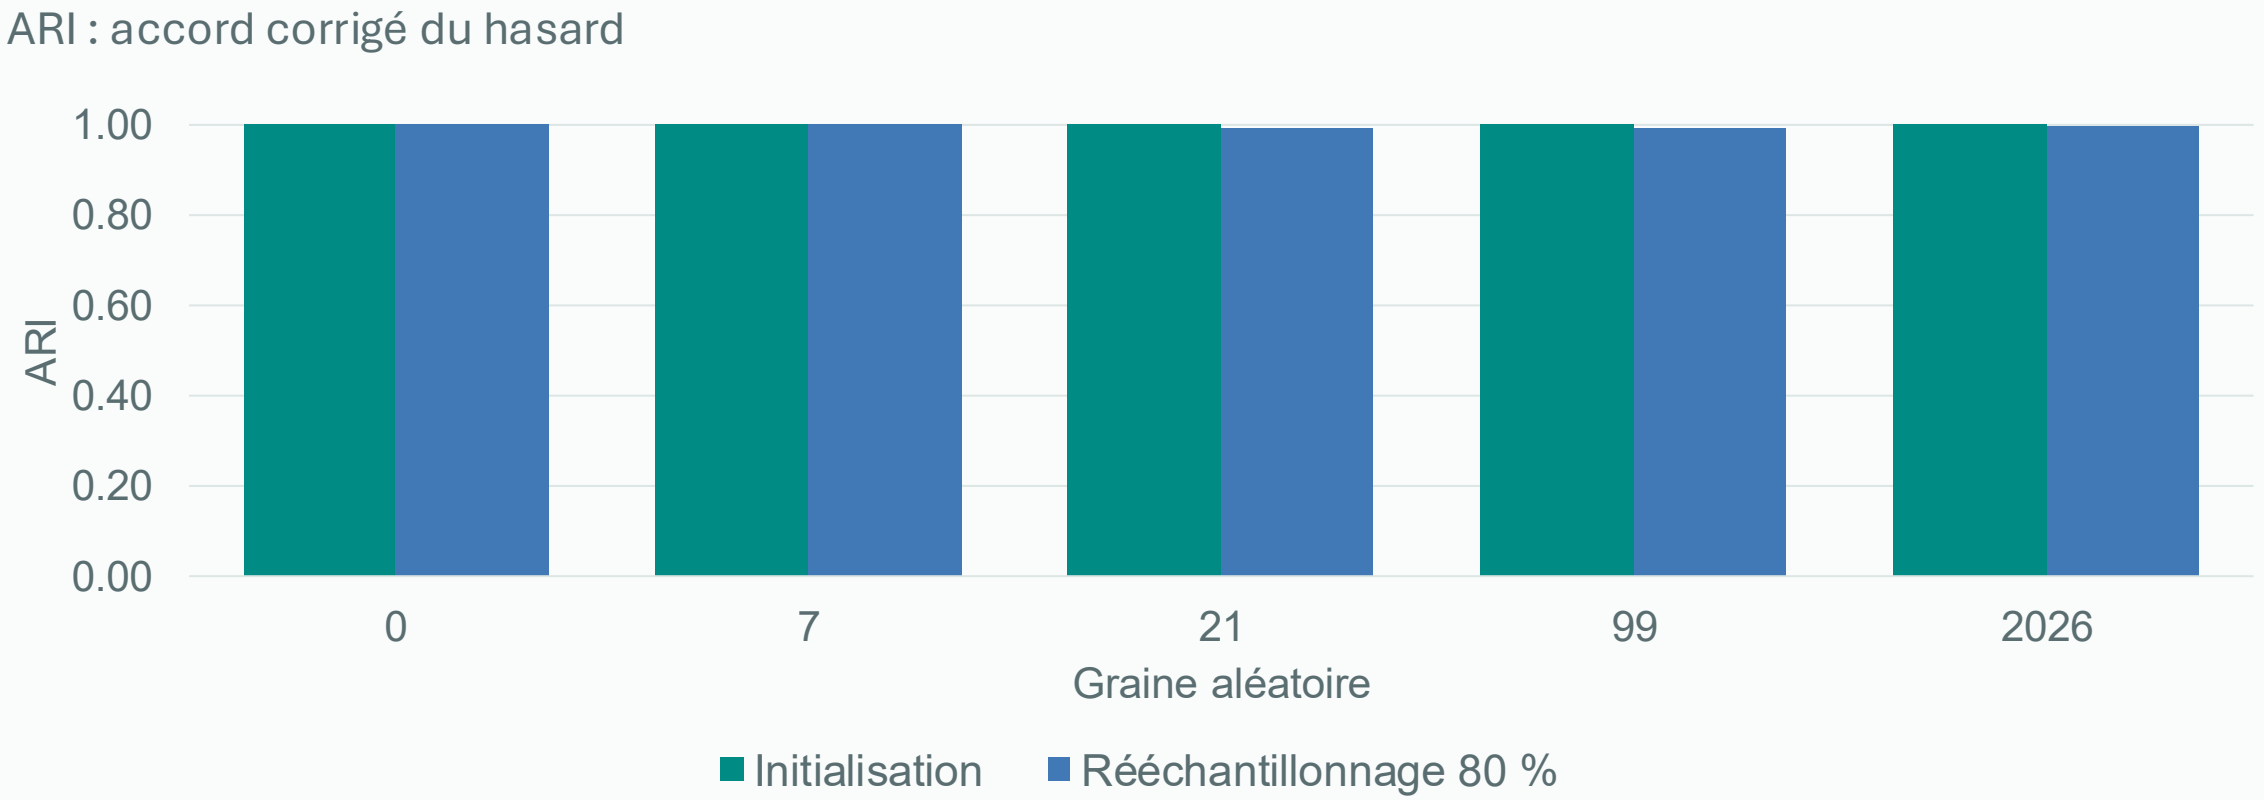
Les motorisations dans chaque groupe

Composition du catalogue au sein de chaque cluster



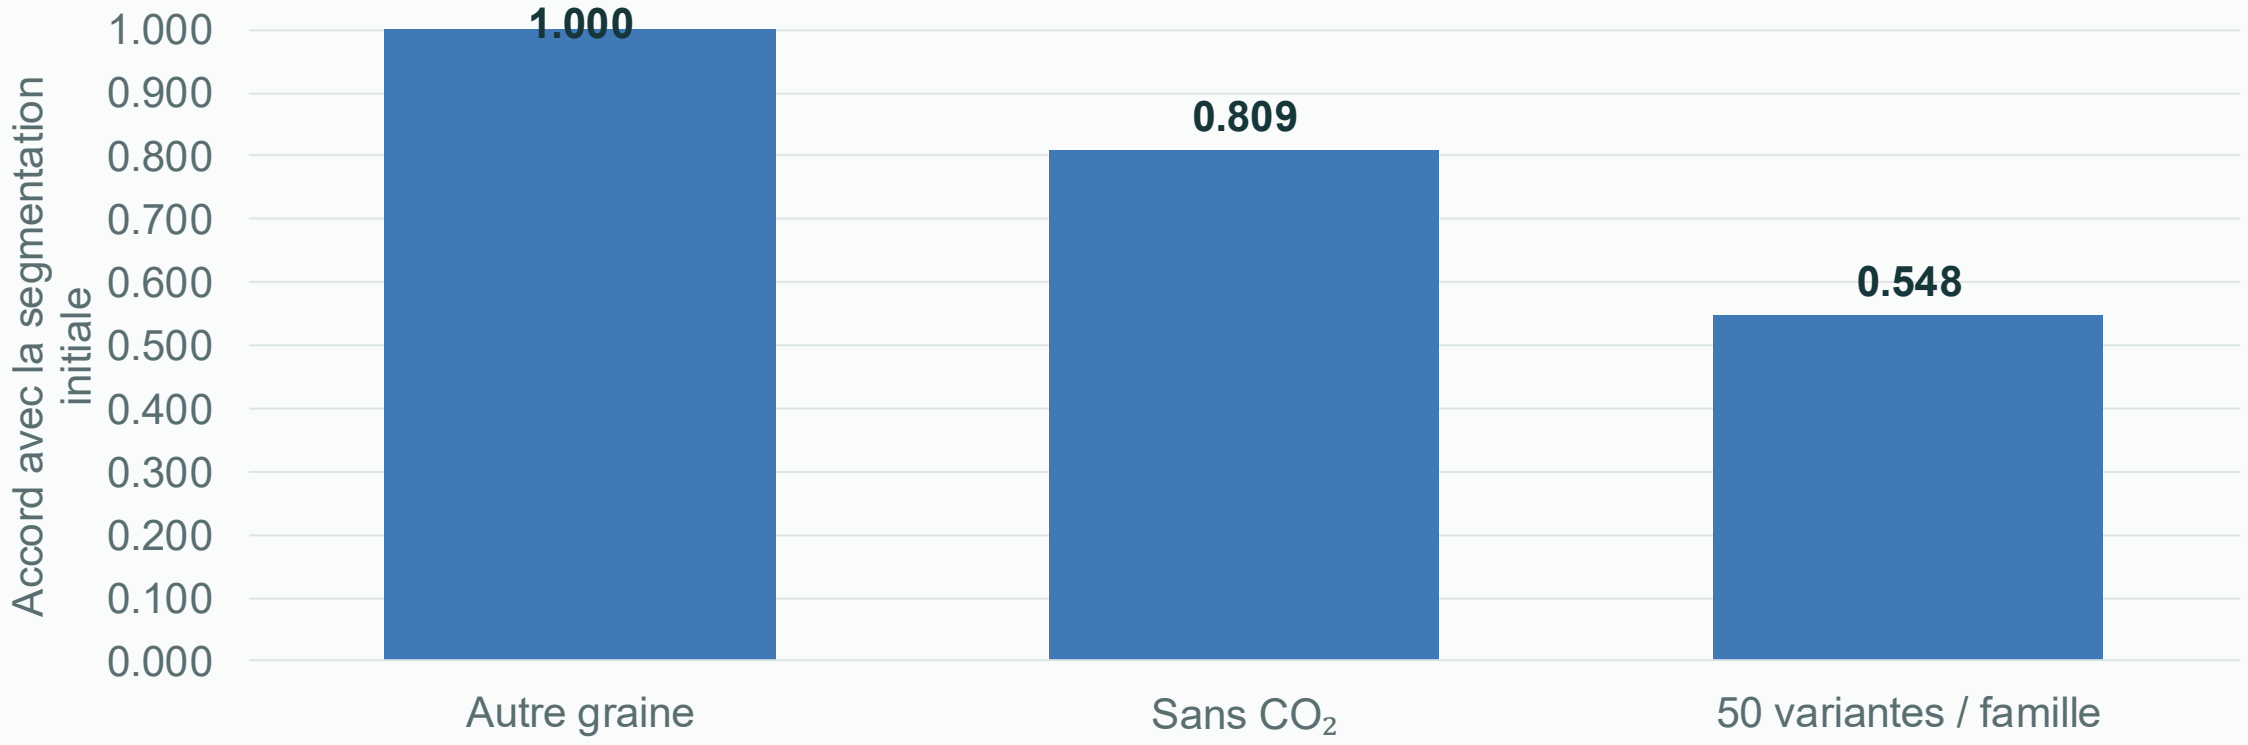
Les catégories décrivent les groupes après leur construction

La stabilité selon l’initialisation



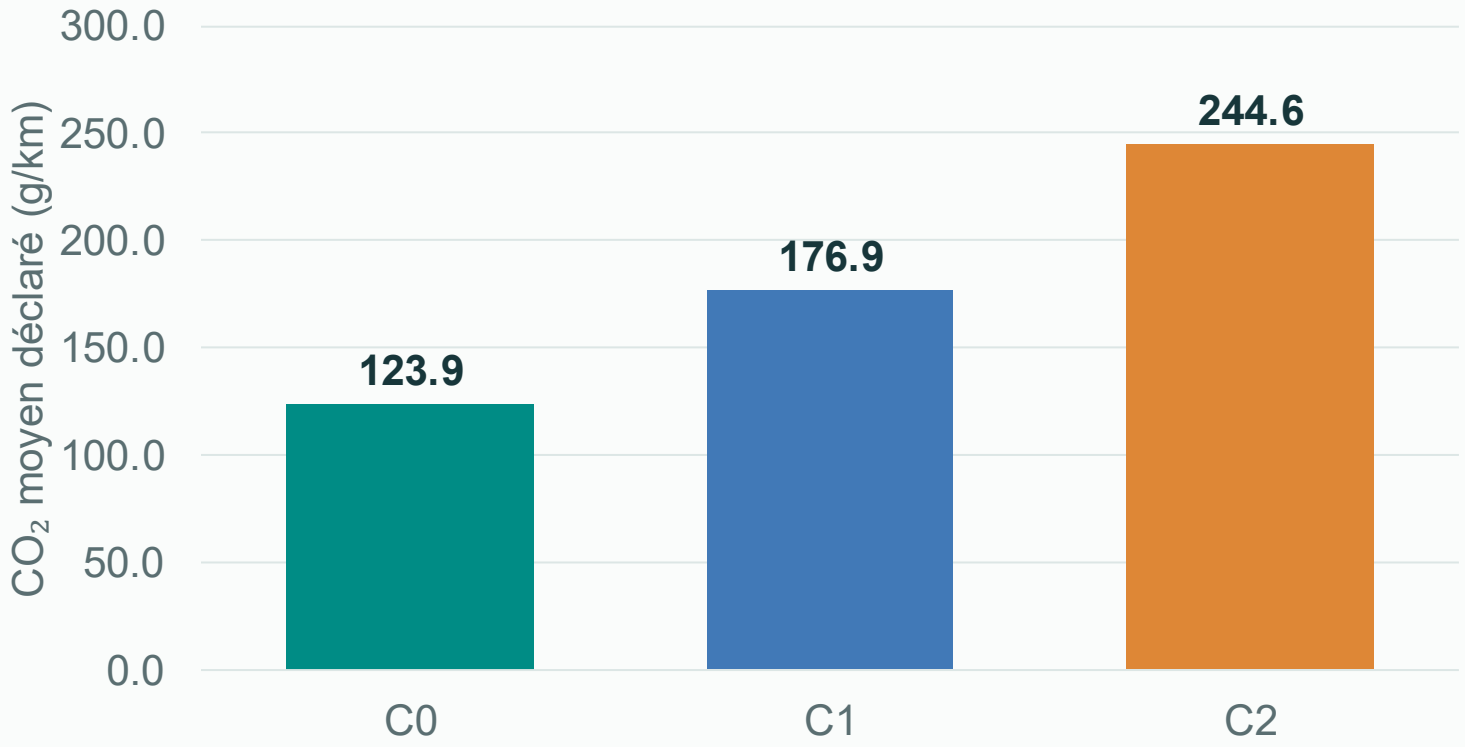
ARI ≥ 0,9948 sur ces essais. La population reste déterminante

Le poids des familles dominantes



Une solution stable à l'initialisation reste sensible à l'échantillon

L’utilité environnementale de la segmentation



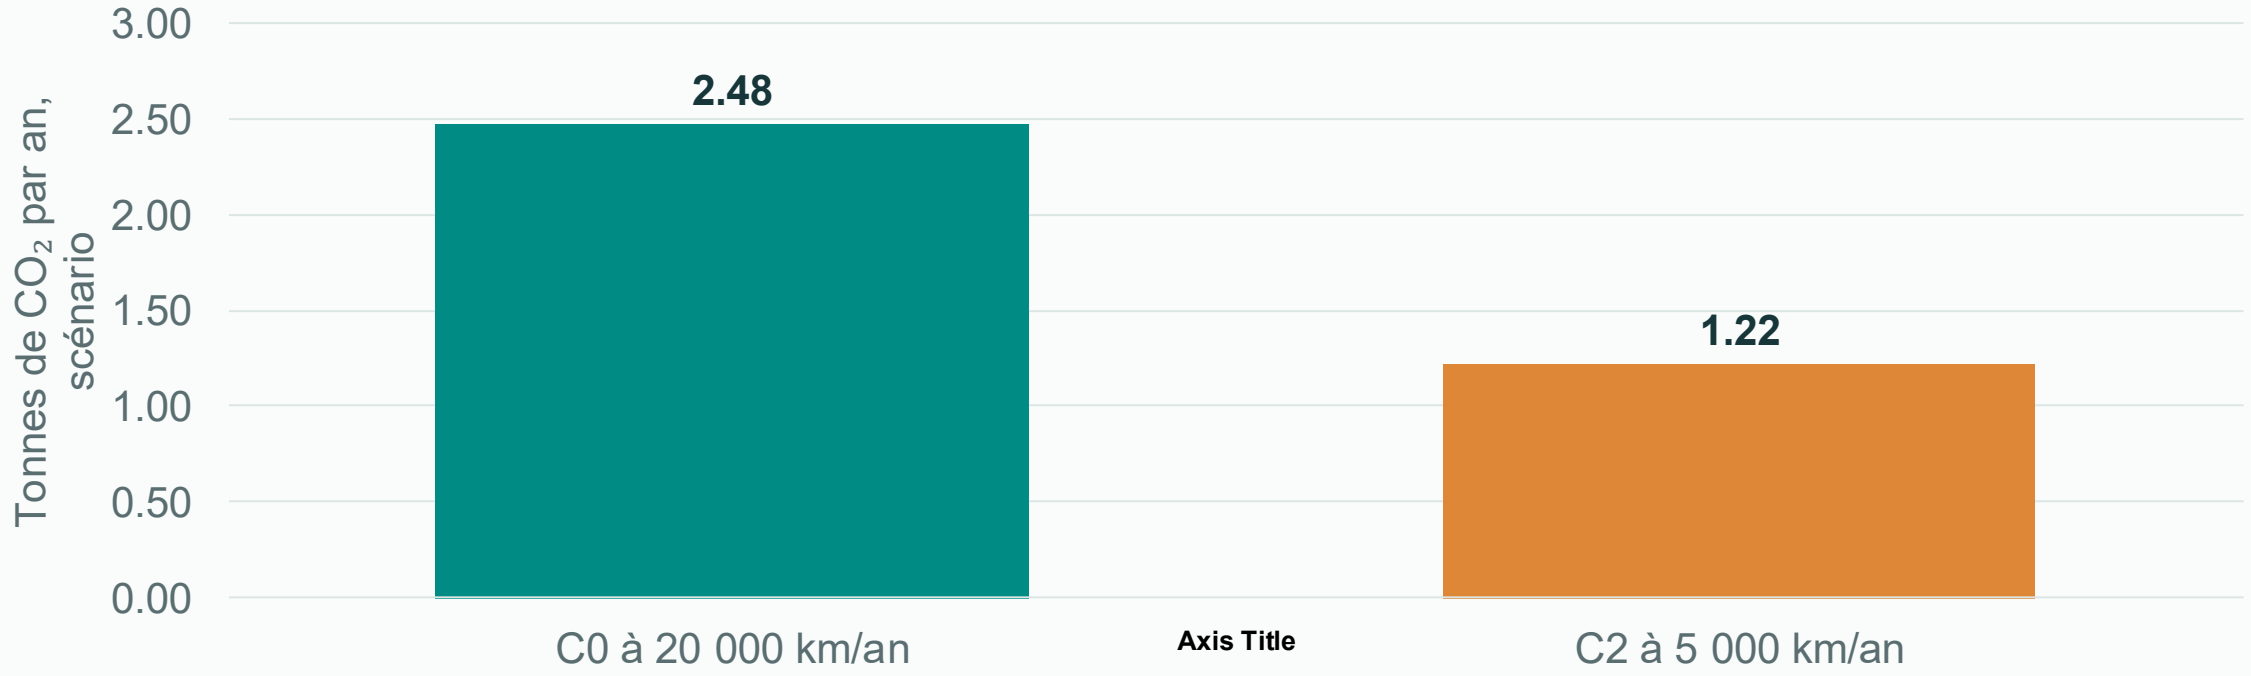
Comparer des profils

Prioriser un audit

CO_2 inclus : l’écart d’émissions participe à la construction des groupes

L’usage change la lecture environnementale

Scénario illustratif : émission déclarée × kilométrage



Kilométrages hypothétiques. Ni émissions réelles ni cycle de vie

Les prochaines expériences

Limite observée	Expérience suivante
Catalogue de 2015	Données récentes et test temporel
Familles dominantes	Pondération liée à l'usage
Distance et valeurs extrêmes	Standardisation robuste, autres méthodes
Usage et cycle de vie absents	Kilométrage, recharge, données amont

Une amélioration répond à une limite mesurée

Ce que permet cette étude

16,8 g/km

MAE sur le test familial

3 profils

Cohérents et descriptifs

ARI 0,548

Après plafonnement des familles

Un support pour enquêter

La décision exige des données d’usage et une validation indépendante