

Le point commun fondamental : même processus

KDD, CRISP-DM et SEMMA racontent la
même histoire (appliquée en atelier)



Compréhension des données

Implication : définir objectifs et sources pour guider le travail



Préparation et nettoyage

Implication : garantir qualité pour des modèles fiables



Analyse et modélisation

Implication : choisir méthodes adaptées aux objectifs



Évaluation

Implication : mesurer performance et pertinence métier



Boucle itérative

Implication : revenir en arrière et affiner jusqu'à déploiement

Différences de philosophie entre KDD, CRISP-DM et SEMMA

Trois récits d'un même processus de data science



KDD

Vision: recherche académique et découverte

Accent sur la découverte de connaissance

Processus orienté expérimentation et validation

CRISP-DM

Vision: industrie, résoudre un problème métier

Phases: compréhension du business puis data science

Orienté livrables et communication inter-équipes

SEMMA

Vision: SAS, processus outillé et opérationnel

Focus sur échantillonnage, exploration, modélisation

Conçu pour implémentation technique rapide

KDD: objectifs et étapes clés

Extraire de la connaissance à partir des données — focalisé sur les données

Sélection des données

Choisir ensembles et variables pertinents pour répondre à la question d'exploration



Pré-traitement

Nettoyer et imputer valeurs manquantes; documenter les décisions de qualité



Transformation

Normaliser, agréger et coder les données; garder trace des transformations




Data Mining

Appliquer méthodes exploratoires et modèles pour révéler motifs et relations



Interprétation et évaluation

Valider découvertes, mesurer signification et utilité métier éventuelle



CRISP-DM : vision orientée métier

Résoudre un problème métier avec la data, étape par étape

Compréhension métier

Point d'ancrage: définir objectifs métier et critères de succès. Point de départ de l'itération.

Déploiement

Mise en production, suivi et mesure d'impact métier en continu.

Évaluation

Valider performance selon critères métier et préparer itérations si nécessaire.



Compréhension des données

Explorer les sources, qualité et variables disponibles pour répondre au besoin métier.

Préparation des données


Nettoyage, transformation et enrichissement pour rendre les données exploitables.

Modélisation

Sélection et entraînement d'algorithmes adaptés aux objectifs métier.

SEMMA: technique et outillage pour l'analyse de données

Processus analytique orienté technique, conçu pour l'outillage SAS



Comparaison étape par étape des méthodes KDD, CRISP-DM et SEMMA

Tableau synthétique pour traduire les étapes et éviter la confusion terminologique

Étape conceptuelle	KDD	CRISP-DM	SEMMA
Compréhension du domaine	Sélection des données (contexte)	Compréhension du métier	Sample (définition du jeu)
Préparation des données	Prétraitement / nettoyage	Préparation des données	Modify (nettoyage et recodage)
Transformation	Transformation / intégration	Construction de données	Transform n/a (souvent dans Modify)
Sélection de variables	Sélection d'attributs	Sélection des variables	Select (choix des variables)
Modélisation	Apprentissage / modélisation	Modélisation	Model (algorithmes et validation)
Évaluation	Évaluation (validité, interprétation)	Évaluation	Assess (évaluation et interprétation)
Déploiement et	Diffusion / utilisation	Déploiement	Déploiement implicite



Point clé commun

KDD, CRISP-DM et SEMMA racontent la même histoire: processus unique, pas de concurrence.



Message

Conserver ce tableau pour mémoire.

Tableau synthèse : critères comparatifs

Comparer KDD, CRISP-DM et SEMMA pour positionner un cours

Critère	KDD	CRISP-DM	SEMMA
Orientation	Données	Métier et cycle complet	 Technique
Métier explicite	Faible	Fort	 Faible
Très utilisé en entreprise	Moins	Très utilisé	 Modéré
Compatible ML moderne	Oui	Oui	 Oui
Adapté à la MSPR	Oui	Oui	 Partiel

Liens directs avec l'atelier — mise en pratique

Suivi des étapes clés

1 Compréhension des données: ce que vous avez noté sur objectifs et variables



Relier vos questions d'atelier à la phase de business understanding

2 Préparation et exploration: nettoyage, transformation et visualisation réalisés



Montrer où vos manipulations s'insèrent dans data preparation

3 Machine learning: la prochaine étape formelle après exploration



Expliquer que le ML vient après préparation et exploration

4 Actionnable: formalisez vos notes en étapes CRISP-DM



2-3 tâches concrètes pour transformer les notes en process

Prompt 1: Résumez 3 décisions d'atelier sous 'Business Understanding'
Choisissez objectifs, métriques, contraintes



Prompt 2: Cartographiez 3 transformations dans 'Data Preparation'
Indiquez source, méthode et justification



Prompt 3: Listez 2 modèles candidats à tester et critères d'évaluation
Précisez métriques et jeux de données pour validation



Conclusion : devenir **Data Scientist** conscient

3 attentes claires pour vos travaux et un conseil sur la reproductibilité



1 Expliquer l'objectif: pourquoi vous analysez ces données

Contexte, question métier et
hypothèses de départ



2 Documenter la préparation: comment vous préparez les données

Nettoyage, transformation,
échantillonnage et choix
techniques



3 Interpréter les résultats: ce que vous tirez des analyses

Conclusions, limites et implications
pour le métier



4 Conseil pratique: rendez tout reproductible

code, versions, seeds et
documentation pour reproduire



Méthodes KDD, CRISP-DM et SEMMA: verbes clés

Résumé ultra-court pour examen ou compte-rendu

KDD: Découvrir Exploration Et Extraction De Connaissance (Data Mining)	CRISP-DM: Décider Orienté Processus Métier Et Choix Méthodologiques	SEMMA: Analyser Centrée Sur Manipulation Et Modélisation Statistique	Pratique: Hybride Fréquent En Pratique On Mélange Souvent Les Trois Approches

Récap visuel et actions concrètes pour l'atelier suivant

Quatre étapes claires pour transformer l'exercice pratique en livrable compréhensible

