

Compléments au Machine Learning et à l'Apprentissage Supervisé

GÉNÉRALISATION • BASELINES • RÉALITÉ MÉTIER

DATE DU RAPPORT

18 Février 2026

SUJET PRINCIPAL

DATA SCIENCE & STRATÉGIE



La notion de généralisation réelle

Au-delà de la simple mémorisation des données.



Données d'Entraînement

Le modèle apprend à identifier des **motifs** et des structures à partir d'exemples historiques connus.



Capacité de Généralisation

L'aptitude du système à appliquer ses connaissances à des **données nouvelles** et inconnues.



Performance Réelle

L'objectif ultime : des prédictions précises dans un contexte **opérationnel** changeant.



Le Défi Majeur

Le machine learning ne consiste pas à créer des modèles qui excellent uniquement sur les données qu'ils ont déjà rencontrées, mais à développer des systèmes capables d'extrapoler intelligemment sans tomber dans le piège de la mémorisation pure (bruit).

Le Sous-ajustement (Underfitting)

🎯 Biais Élevé (High Bias)

Le modèle fait des hypothèses trop fortes sur les données et ignore les motifs importants. Il en résulte une représentation **trop simpliste** de la réalité.

📉 Performance Médiocre

- Erreur élevée sur les **données d'entraînement**
- Erreur élevée sur les **données de test**

Causes et Caractéristiques Principales



Modèle trop simple

Ex: Utiliser un modèle linéaire pour des données non linéaires.



Régularisation excessive

Contraint trop fortement le modèle, l'empêchant d'apprendre.



Variables faibles

Manque de caractéristiques pertinentes pour prédire la cible.



Entraînement insuffisant

Pas assez d'itérations pour converger vers une solution optimale.



Le modèle "ne parvient pas à apprendre".

Le Sur-ajustement

L'excès de zèle du modèle (Overfitting)

⚠ VARIANCE ÉLEVÉE

🔍 Phénomène

Le modèle apprend les données d'entraînement de manière excessivement détaillée, incluant le **bruit** et les **anomalies spécifiques**.

ENTRAÎNEMENT

Excellent

Précision maximale

TEST / RÉEL

Faible

Échec de généralisation

🔧 Origines du Problème



Modèle trop complexe

Réseaux de neurones trop profonds ou trop de paramètres.



Excès de variables (Features)

Inclusion de caractéristiques non pertinentes ou bruitées.



Données insuffisantes

Volume trop faible pour apprendre des motifs robustes.



Absence de régularisation

Rien ne contraint le modèle à rester simple.

Le compromis Biais-Variance

CONCEPT CLÉ

🎯 Biais Élevé (Sous-ajustement)

Le modèle est trop simple et ignore les motifs importants (hypothèses trop fortes).


⚡ Variance Élevée (Sur-ajustement)

Le modèle est trop sensible au bruit et aux fluctuations des données d'entraînement.

ÉQUATION DE L'ERREUR TOTALE

$$\text{Erreur} = \text{Biais}^2 + \text{Variance} + \varepsilon$$

ε : Erreur irréductible (bruit intrinsèque)



L'objectif est de trouver le point où l'erreur sur les données de test est minimisée.

La notion de Baseline

Qu'est-ce qu'une Baseline ?

Un modèle *intentionnellement simple* qui sert de point de comparaison indispensable pour évaluer la véritable performance d'algorithmes plus complexes.



Attente Minimale

Quantifie si la complexité ajoutée apporte une amélioration réelle et significative.



Valeur Métier Rapide

Peut être "suffisamment bonne" pour un déploiement initial sans développement intensif.

LOGIQUE DE VALIDATION

MODÈLE TRIVIAL (BASELINE)

RÉFÉRENCE




Score X

VS

MODÈLE COMPLEXE

OBJECTIF



Score X +

Δ

*"L'amélioration doit être statistiquement significative
(intervalles de confiance disjoints)."*

Exemples de modèles triviaux



Régression

✓ Moyenne

Prédit systématiquement la moyenne de la variable cible des données d'entraînement.

✓ Médiane

Plus robuste aux valeurs aberrantes (outliers) que la moyenne.

Objectif : Établir une erreur minimale (RMSE / MAE) à battre.



Classification

✓ Classe Majoritaire

Prédit toujours la classe la plus fréquente. Crucial pour les jeux de données déséquilibrés.

✓ Aléatoire (Random)

Génère des prédictions au hasard. Utile comme point de référence zéro information.

Objectif : S'assurer que le modèle est plus "intelligent" que le hasard.



Séries Temporelles

Utilisation de la **valeur précédente** (t-1) comme prédiction.



Modèles Simples

Régression linéaire simple ou k-NN (k-plus proches voisins).

Échecs liés aux variables et au signal



Mauvaises Variables (Features)

❌ Variables Non Pertinentes

Introduction de bruit qui dilue le signal utile et complexifie inutilement le modèle.



Fuite de Données (Data Leakage)

Inclusion d'informations du futur ou de la cible. Performance artificielle en test, échec total en production.



Signal Faible



Définition (Ansoff)

Information fragmentaire, obsolète et largement anticipative permettant de prédire des transformations.



Le Challenge Technique

Signaux informels et improbables, souvent dilués dans une masse de données bruyantes.



Exemple : Projet "Signaux Faibles"

Utilise l'IA pour agréger des données financières et sociales afin de prédire les défaillances d'entreprises.



Un modèle techniquement parfait sur de mauvaises bases sera inutile ou trompeur dans le monde réel.

Données insuffisantes et phénomènes mal représentés

Quand la réalité dépasse le modèle

9 / 10

Qualité et Volume des Données

Volume Insuffisant

Empêche la capture de la complexité réelle. Risque élevé de **sous-ajustement** ou de **sur-ajustement** sur des bruits.

Données Bruitées & Valeurs Manquantes

Erreurs, incohérences ou absences d'infos qui biaisent les résultats ou réduisent la base d'apprentissage exploitable.

Échantillon Non Représentatif

Décalage entre les données d'entraînement et la réalité opérationnelle.
Dégradation immédiate des performances en production.

Dérive et Représentation

Concept Drift (Dérive)

Les relations entre les variables d'entrée et la cible **évoluent avec le temps**.

Exemple : Un modèle de prédiction de demande devenu obsolète suite à un changement radical des habitudes de consommation.

Mauvaise Modélisation Métier

-  Manque de collaboration étroite avec les experts métier.
-  Objectifs du modèle non alignés avec les besoins business réels.
-  Incapacité à capturer la dynamique réelle du phénomène.



Un modèle techniquement sophistiqué est inutile s'il repose sur des données pauvres ou s'il ignore l'évolution de son environnement.

Conclusion : De la théorie à la réalité métier

*"La réussite d'un projet de Machine Learning transcende la technique. Elle repose sur une approche **holistique** unissant rigueur scientifique et vision opérationnelle."*



Maîtrise Technique

Compréhension fine de la **généralisation** et gestion du compromis **biais-variance** pour des modèles robustes.



Rigueur d'Évaluation

Validation systématique par rapport à des **baselines** pour prouver la véritable valeur ajoutée métier.



Ancrage Métier

Identification des **signaux faibles** et collaboration avec les experts pour éviter la **dérive de concept**.