


Préparation des données et apprentissage supervisé



Préparer un dataset pour l'apprentissage automatique

Prétraitement des données

Encodage, normalisation,
split train/test

Modèles supervisés

Régression, arbres de
décision, KNN

Évaluation

MAE, RMSE, précision,
rappel, F1-score

Introduction à l'apprentissage supervisé

Définition

L'apprentissage supervisé est une branche fondamentale du machine learning où un algorithme apprend à partir d'un ensemble de données étiquetées pour faire des prédictions ou des classifications sur de nouvelles données.

Importance

La performance et la fiabilité d'un modèle d'apprentissage supervisé sont intrinsèquement liées à la qualité et à la préparation des données d'entrée. Une bonne préparation des données est donc essentielle pour obtenir des résultats optimaux.

Flux de travail en ML supervisé



Préparation des données

Encodage, normalisation, division en ensembles d'entraînement et de test



Choix et entraînement du modèle

Sélection des algorithmes appropriés et ajustement des paramètres



Évaluation du modèle

Utilisation de métriques pour juger de la performance et identifier les améliorations



Déploiement et maintenance

Mise en production et surveillance du modèle dans le environnement réel

Prétraitement des données - Vue d'ensemble

! Importance du prétraitement

Avant toute modélisation en apprentissage automatique, le prétraitement des données est une étape cruciale et incontournable. Il transforme les données brutes en un format adapté aux algorithmes, améliorant ainsi la performance et la robustesse des modèles.



Encodage

Conversion des variables catégorielles en représentation numérique.

- One-Hot Encoding pour les variables nominales
- Label Encoding pour les variables ordinales



Normalisation

Mise à l'échelle des caractéristiques pour améliorer la performance des algorithmes.

- Standardisation (moyenne=0, écart-type=1)
- Normalisation (plage de valeurs réduite)



Division des données

Séparation du dataset en ensembles d'entraînement et de test.

- Ensemble d'entraînement (70-80% des données)
- Ensemble de test (20-30% des données)

Un bon prétraitement des données est la foundation d'un modèle de machine learning efficace.

Encodage des variables catégorielles

📄 Qu'est-ce que l'encodage ?

Les variables catégorielles doivent être encodées car les algorithmes de machine learning ne peuvent pas interpréter directement les textes. L'encodage convertit ces catégories en une représentation numérique.

🔗 One-Hot Encoding

Technique couramment utilisée pour les variables catégorielles nominales (sans ordre intrinsèque). Elle crée de nouvelles colonnes binaires pour chaque catégorie unique.

- Chaque catégorie devient une colonne
- Valeur 1 si l'observation appartient à cette catégorie, 0 sinon
- Évite d'imposer un ordre aux catégories

🔧 Utilisation de OneHotEncoder

L'outil **OneHotEncoder** de Scikit-learn permet d'appliquer facilement cet encodage aux données.

```
from sklearn.preprocessing import OneHotEncoder
encoder = OneHotEncoder()
X_encoded = encoder.fit_transform(X)
```

🧪 Exemple de One-Hot Encoding

Avant encodage :

Couleur
Rouge
Bleu
Vert
Rouge



Après encodage :

Couleur_Rouge	Couleur_Bleu	Couleur_Vert
1	0	0
0	1	0
0	0	1
1	0	0

Avantages de l'One-Hot Encoding :

- Ne impose pas d'ordre aux catégories
- Crée des variables indépendantes
- Facile à interpréter

Normalisation des données

🏗 Pourquoi la mise à l'échelle est-elle importante ?

De nombreux algorithmes de machine learning sont sensibles à l'échelle des valeurs d'entrée. Des algorithmes basés sur la distance (comme KNN) ou ceux utilisant des descentes de gradient (comme la régression linéaire ou logistique) peuvent être fortement influencés par des caractéristiques ayant des plages de valeurs très différentes.

⚖ Standardisation

La standardisation transforme les données pour qu'elles aient une moyenne de 0 et un écart-type de 1.

$$x' = (x - \mu) / \sigma$$

- x : valeur originale
- μ (mu) : moyenne des valeurs
- σ (sigma) : écart-type des valeurs
- x' : valeur standardisée

</> Utilisation de StandardScaler

StandardScaler de Scikit-learn implémente cette transformation. Il garantit que les données ont une moyenne proche de 0 et un écart-type de 1.


☰ Exemple avec StandardScaler

Standardisation de la caractéristique Âge

Âge	Âge standardisé
20	≈ -1.34
30	≈ -0.45
40	≈ 0.45
50	≈ 1.34

Moyenne (μ) = 35, Écart-type (σ) ≈ 11.18

Visualisation de la standardisation



Division du dataset

↔ Processus de division



Entraînement (70%)

Test (30%)


Division aléatoire des données

Assure que les ensembles représentent fidèlement la distribution globale des données

★ Importance de cette étape

- ✓ Évalue la performance du modèle sur des données **jamais vues** pendant l'entraînement
- ✓ Fournit une estimation réaliste de la capacité du modèle à généraliser à de nouvelles données
- ✓ Permet d'identifier les éventuels surajustements (overfitting)

📊 Proportions recommandées



Automatisation avec Pipeline

Qu'est-ce qu'un Pipeline ?

L'objet **Pipeline** de Scikit-learn permet d'enchaîner séquentiellement plusieurs étapes de prétraitement et un estimateur final (le modèle).

Avantages

- Garantit que les mêmes transformations sont appliquées de manière cohérente aux données d'entraînement et de test
- Évite les fuites de données (data leakage)
- Simplifie le flux de travail
- Rend le code plus propre, plus robuste et plus facile à maintenir

Exemple d'utilisation

```
# Création d'un pipeline
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.linear_model import LogisticRegression

pipeline = Pipeline([
    ('encoder', OneHotEncoder(drop='first')),
    ('scaler', StandardScaler()),
    ('model', LogisticRegression())
])

# Entraînement du pipeline
pipeline.fit(X_train, y_train)

# Prédictions
predictions = pipeline.predict(X_test)
```

Fonctionnement du Pipeline



Résultats

Prédictions sur les données de test



Encodage

OneHotEncoder pour les variables catégorielles



Normalisation

StandardScaler pour mettre à l'échelle

Modèles supervisés - Introduction

Problèmes de régression

Vise à prédire une valeur continue (par exemple, le prix d'une maison).



Sortie continue

Prédiction de valeurs numériques continues

Problèmes de classification

A pour objectif de prédire une catégorie discrète (par exemple, si un e-mail est un spam ou non).



Sortie catégorielle

Prédiction de classes discrètes



Catégories d'algorithmes supervisés



Modèles linéaires

Régression linéaire, Régression logistique



Arbres de décision

Forêts aléatoires, XGBoost



Voisins proches

K-Plus Proches Voisins (KNN)



Réseaux neuronaux

Perceptrons, Réseaux de neurones profonds

Modèles de régression

Régression linéaire

Modèle fondamental utilisé pour prédire une variable cible continue à partir d'une ou plusieurs variables prédictives.


Principes fondamentaux

- Établit une relation linéaire entre les variables
- Cherche à trouver la droite qui minimise la somme des carrés des erreurs
- Les erreurs sont les différences entre les valeurs prédites et les valeurs réelles

Applications

- Prédiction de prix (immobilier, produits)
- Analyse de tendance et extrapolation
- Modélisation de relations causales

Visualisation de la régression linéaire



Comment ça marche?

La régression linéaire cherche à minimiser la somme des carrés des erreurs. Elle trouve la droite qui passe au plus près de tous les points, en minimisant la distance verticale entre les points et la droite.

Régression logistique

Principes

La régression logistique est un algorithme de classification binaire malgré son nom. Il modélise la probabilité qu'une instance appartienne à une classe donnée.

Contrairement à la régression linéaire, elle utilise une fonction logistique (sigmoïde) pour transformer la sortie linéaire en une probabilité comprise entre 0 et 1.


Transformation en probabilités

La fonction sigmoïde prend la forme suivante :

$$\sigma(z) = 1 / (1 + e^{-z})$$

Où z est la combinaison linéaire des entrées. Cette fonction transforme n'importe quel valeur réelle en une probabilité comprise entre 0 et 1.

Fonction sigmoïde



Applications

- ✓ Classification binaire (spam/non-spam)
- ✓ Prédiction de probabilités
- ✓ Modélisation des relations logistiques

Arbres de décision

🔗 Fonctionnement

Les arbres de décision sont des modèles polyvalents qui divisent l'espace des données en sous-régions basées sur des règles de décision simples.

- Chaque nœud interne représente un test sur un attribut
- Chaque branche représente le résultat du test
- Chaque feuille représente une décision ou une valeur prédite

🔗 Applications

📈 Régression

Prédiction d'une variable continue par partitionnement de l'espace des features

🔗 Classification


Prédiction d'une catégorie discrète en fonction des caractéristiques

🔗 Structure et principes

Les arbres de décision se construisent de manière récursive en :

1. Sélection d'un attribut à tester
2. Division des données selon les valeurs de l'attribut
3. Création de nœuds enfants pour chaque subdivision
4. Répétition jusqu'à atteindre des critères d'arrêt

Exemple de structure d'arbre de décision



K-Plus Proches Voisins (KNN)

? Qu'est-ce que KNN?

KNN est un classifieur non-paramétrique basé sur l'instance. Pour classer un nouveau point de données, il identifie les 'K' points de données les plus proches dans l'ensemble d'entraînement et attribue au nouveau point la classe majoritaire parmi ces 'K' voisins.


⚙️ Fonctionnement

- Calcul de la distance entre le point à classer et tous les points d'entraînement
- Sélection des 'K' points les plus proches
- Vote majoritaire des classes des 'K' voisins
- Attribution de la classe la plus votée au point à classer

⚙️ Choix du paramètre K

- Les valeurs impaires sont préférables pour éviter les égalités
- La validation croisée peut aider à trouver le K optimal
- Un K trop petit rend le modèle sensible au bruit
- Un K trop grand peut adoucir les frontières de décision

Visualisation du fonctionnement de KNN



💡 **Avantages :** Simple à comprendre, pas d'hypothèse sur la forme des données

⚠️ **Inconvénients :** Coût computationnel élevé, sensibilité aux caractéristiques non pertinentes

Évaluation des modèles - Introduction

Importance de l'évaluation objective

- ✓ Permet de comprendre l'efficacité d'un modèle
- ✓ Identifie les domaines d'amélioration
- ✓ Permet de comparer différents modèles
- ✓ Évalue la capacité du modèle à généraliser à de nouvelles données

Comment choisir la bonne métrique?

La métrique d'évaluation doit être adaptée au type de problème à résoudre (régression ou classification) et aux objectifs spécifiques du projet. Elle doit également tenir compte des caractéristiques des données et de la situation métier.

Types d'évaluation selon le problème



Régression

Prédiction d'une valeur continue (prix, température, etc.)



MAE



RMSE



Classification


Prédiction d'une catégorie ou d'une classe (spam/ham, rouge/vert/bleu, etc.)



Précision



Rappel



F1-score

Métriques pour la régression



Erreur Absolue Moyenne (MAE)

Moyenne des valeurs absolues des erreurs de prédiction. Représente la magnitude moyenne des erreurs sans tenir compte de leur direction.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Une MAE de 0 indique un modèle parfait.



Erreur Quadratique Moyenne (RMSE)

Racine carrée de la moyenne des carrés des erreurs. Pénalise davantage les erreurs importantes que la MAE.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Une RMSE de 0 indique un modèle parfait.



Comparaison MAE vs RMSE

Caractéristique	MAE	RMSE
Sensibilité aux erreurs	Moins sensible aux erreurs importantes (valeurs aberrantes).	Plus sensible aux erreurs importantes, les pénalise davantage.
Interprétation	Facile à interpréter, représente l'erreur moyenne en unités de la variable cible.	Plus difficile à interpréter directement en unités de la variable cible en raison de la mise au carré.
Cas d'usage	Préférable lorsque les erreurs importantes ne doivent pas être sur-pénalisées.	Préférable lorsque les erreurs importantes sont particulièrement indésirables.



Conseil : Utilisez RMSE lorsque les valeurs aberrantes sont importantes, sinon MAE pour une interprétation plus simple.

Métriques pour la classification

Matrice de Confusion

Tableau qui résume les performances d'un algorithme de classification binaire :

	Prédict Positif	Prédict Négatif
Réel Positif	VP	FN
Réel Négatif	FP	VN

 Les vrais positifs et négatifs (en surbrillance) représentent les bonnes prédictions, tandis que les faux positifs et négatifs (en erreur) représentent les erreurs du modèle.

🎯 Précision (Precision)

Proportion de prédictions positives qui étaient réellement correctes.

$$\text{Précision} = \text{VP} / (\text{VP} + \text{FP})$$

🔍 Rappel (Recall)

Proportion d'instances positives réelles qui ont été correctement identifiées.

$$\text{Rappel} = \text{VP} / (\text{VP} + \text{FN})$$

★ F1-score

Moyenne harmonique de la précision et du rappel. Équilibre entre les deux métriques.

$$\text{F1-score} = 2 \times (\text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel})$$

 Un modèle avec une précision élevée peut avoir un faible rappel et vice-versa. Le F1-score aide à équilibrer ces deux métriques.

Conclusion

✓ Synthèse du flux de travail

Un projet d'apprentissage supervisé suit un flux de travail structuré, débutant par une préparation minutieuse des données.

La phase de modélisation implique l'application d'algorithmes adaptés en fonction de la nature du problème (régression ou classification).

L'évaluation rigoureuse du modèle à l'aide de métriques pertinentes est indispensable pour juger de sa performance.

💡 Points clés

- La qualité de la préparation des données est cruciale pour le succès du modèle
- Le choix des métriques d'évaluation doit être aligné avec les objectifs du projet
- Le machine learning est un processus itératif qui nécessite une expérimentation constante

🔧 Flux de travail en ML supervisé



Le succès d'un modèle repose non seulement sur le choix de l'algorithme, mais aussi et surtout sur la qualité de la préparation des données et la pertinence des métriques d'évaluation.