

Les fondamentaux du Machine Learning supervisé

Du nettoyage des données à la prédiction et à l'évaluation d'un modèle.

Observer → préparer → apprendre → prédire → évaluer

Comprendre les données

- **Jusqu'ici** : importer, inspecter, nettoyer et explorer les données.
- Identifier les valeurs manquantes, distributions et valeurs atypiques.
- Construire une analyse exploratoire des données (EDA).

Apprendre à partir des données

- **Maintenant** : apprendre une relation à partir d'exemples connus.
- Produire une prédiction sur de nouvelles observations.
- Mesurer puis interpréter la qualité de cette prédiction.

1. PRINCIPE

Qu'est-ce que l'apprentissage supervisé ?

Les entrées	La réponse attendue
X - variables explicatives / features • Informations disponibles pour effectuer la prédiction. • Ex. surface, année de construction, ville, type de bâtiment...	y - cible / target • Ce que l'on cherche à prédire. • Ex. energy_consumption_kwh.

Pendant l'apprentissage : X connus $\rightarrow$ y connu | Lors de la prédiction : nouveau X $\rightarrow$?

Supervisé = les bonnes réponses sont connues pendant l'apprentissage.

2. DEUX FAMILLES

Régression ou classification ?

Le type de problème dépend principalement de la nature de la cible y .

	RÉGRESSION	CLASSIFICATION
Objectif	Prédire une valeur	Prédire une catégorie
Nature de y	Numérique, généralement continue	Classe
Exemple	187,4 kWh	Classe D
Question	« Combien ? »	« Quelle classe ? »

Régression et classification sont toutes les deux de l'apprentissage supervisé.

3. RÉGRESSION

Prédire une valeur numérique

Une **régression** cherche à estimer une valeur numérique à partir des caractéristiques disponibles.

Exemples de cibles	Idée essentielle
• Consommation énergétique • Émissions de CO$\blacksquare$ • Prix • Température • Quantité de déchets	Attention au vocabulaire Régression $\neq$ forcément régression linéaire. La régression désigne le problème à résoudre. Plusieurs algorithmes peuvent résoudre ce problème.

Le problème est une régression parce que y est une valeur numérique - pas parce que nous utilisons une droite.

4. MODÈLES DE RÉGRESSION

Régression linéaire, arbre de décision et Random Forest

Modèle	Principe	Forces	Limites
Régression linéaire	Cherche une relation linéaire : $y = b_0 + b_1X_1 + \dots$	Simple, rapide, interprétable	Peut manquer les relations complexes
Arbre de décision	Succession de règles et de découpages	Intuitif, non linéaire	Peut sur-apprendre s'il devient trop profond
Random Forest	Combine de nombreux arbres et agrège leurs prédictions	Robuste, flexible, performant sur données tabulaires	Plus complexe, moins directement interprétable

Autres exemples : KNN Regressor, Gradient Boosting, SVR, réseaux de neurones...

Il n'existe pas de meilleur algorithme dans l'absolu.

5. COMPARER

Pourquoi tester plusieurs modèles ?

Un algorithme plus complexe n'est **pas automatiquement meilleur**.

Méthode	Exemple A - RMSE	Exemple B - RMSE
Prédiction naïve	65 kWh	65 kWh
Régression linéaire	48 kWh	42 kWh
Random Forest	32 kWh	47 kWh

Un modèle complexe doit justifier sa complexité.

La performance n'est pas le seul critère : interprétabilité, robustesse, temps de calcul, coût, maintenance et contraintes métier comptent aussi.

Prédire une catégorie

Deux classes	Plusieurs classes
Classification binaire • Deux classes possibles. • Réemployable / non réemployable • Fraude / non fraude • Panne / pas de panne	Classification multiclasse • Plusieurs catégories possibles. • Classe énergétique A à G • Type de déchet • Catégorie d'équipement

Quelques modèles : régression logistique, KNN, arbre de décision, Random Forest Classifier.

Malgré son nom, la régression logistique est principalement utilisée pour la classification.

Avant le modèle : préparer des données fiables

Un modèle apprend à partir de ce que nous lui fournissons. Une donnée incorrecte, incohérente ou mal préparée peut donc produire un mauvais modèle.

Contrôles essentiels	Valeurs manquantes
• Contrôler les types • Traiter les doublons • Examiner les valeurs aberrantes • Choisir les variables pertinentes	• Traiter les valeurs manquantes • Supprimer certaines observations si justifié • Créer une catégorie « Inconnu » • Utiliser une stratégie d'imputation adaptée

Valeur manquante $\neq$ automatiquement « remplacer ». Première question : pourquoi cette valeur manque-t-elle ?

8. IMPUTATION

Moyenne, médiane... ou autre chose ?

Situation	Stratégie fréquente	Pourquoi ?
Numérique assez symétrique	Moyenne	Représente correctement le centre si peu d'outliers
Numérique asymétrique / outliers	Médiane	Beaucoup moins sensible aux valeurs extrêmes
Catégorielle	Mode ou « Inconnu »	Respecte la nature qualitative de la variable
Temporelle	Interpolation / valeur précédente...	Possible si la continuité temporelle a un sens métier

Exemple : 80 - 90 - 95 - 100 - 110 - 120 - 1000. La valeur 1000 tire fortement la moyenne vers le haut ; la médiane reste plus représentative d'une observation centrale.

Aucune règle automatique ne remplace la compréhension du contexte et de la cause des valeurs manquantes.

Préprocesseur et pipeline : deux notions différentes

Une étape de transformation	La chaîne complète
Préprocesseur • Transforme les données brutes avant le modèle. • Numérique : imputation, standardisation... • Catégoriel : imputation, encodage... • <code>ColumnTransformer</code> permet de traiter différemment les colonnes.	Pipeline • Enchaîne automatiquement plusieurs étapes. • Données → préprocesseur → modèle → prédiction. • Rend les transformations reproductibles. • Aide à limiter les fuites d'information.

Le préprocesseur est une partie du pipeline.

Train / Test : apprendre puis vérifier

Apprentissage	Évaluation
TRAIN • Données utilisées pour apprendre les transformations. • Données utilisées pour entraîner le modèle. • <code>fit(X_train, y_train)</code>	TEST • Données mises de côté pendant l'apprentissage. • Servent à évaluer le modèle sur des observations non utilisées pour apprendre. • <code>predict(X_test)</code>

Cas des valeurs manquantes : la moyenne ou la médiane d'imputation doit être apprise sur le TRAIN, puis la même valeur est appliquée au TEST.

Le jeu de test ne doit pas aider à préparer le modèle qu'il doit ensuite évaluer.

R² et RMSE : mesurer une régression

Comprendre ce que le modèle explique	Comprendre l'ampleur des erreurs
R² - coefficient de détermination • Mesure la part de variabilité de la cible expliquée relativement à une référence. • R² = 1 : prédictions parfaites. • R² = 0 : pas mieux que la référence basée sur la moyenne. • R² < 0 : moins bien que cette référence. • R² = 0,72 ≠ « 72 % de précision ».	RMSE - Root Mean Squared Error • Mesure l'écart entre valeurs réelles et prédites. • Pénalise davantage les grosses erreurs. • Conserve l'unité de la cible. • Ex. RMSE = 35 kWh. • Plus faible = meilleur, à comparaison équivalente.

Une métrique n'est jamais « bonne » ou « mauvaise » sans contexte métier.

La démarche supervisée complète

1. Question métier	2. Dataset & EDA	3. Choisir y	4. Choisir X	5. Train / Test
6. Prétraiter	7. Entraîner	8. Prédire	9. Évaluer	10. Interpréter

Un modèle qui obtient un bon score est-il nécessairement un bon modèle ? Non.

Il faut encore examiner : **généralisation, baseline, underfitting/overfitting, biais-variance, data leakage, signal disponible et sens métier.**