




L'Apprentissage Non Supervisé

Clustering et Réduction de Dimension



Clustering



Réduction de Dimension

Comprendre et appliquer les méthodes non supervisées

22 octobre 2025

Introduction à l'Apprentissage Non Supervisé



Définition

L'apprentissage non supervisé est une branche du machine learning qui se concentre sur la découverte de motifs et de structures cachées dans des données non étiquetées.



Objectifs

- Explorer et comprendre la structure des données
- Découvrir des patterns cachés
- Réduire la complexité des données
- Préparer les données pour l'analyse approfondie

Différenciation avec l'apprentissage supervisé



Non supervisé : Utilise des données sans étiquettes connues



Supervisé : Utilise des données avec des étiquettes connues pour entraîner un modèle

Deux grandes familles de méthodes



Clustering

Regrouper des données similaires



Réduction de dimension

Simplifier la représentation des données tout en préservant l'information essentielle

Notions Fondamentales du Clustering




Distance

La distance mesure la dissimilarité entre deux points de données.

Métriques courantes :

Distance euclidienne : La ligne droite entre deux points dans un espace multidimensionnel.


Distance de Manhattan : La somme des différences absolues des coordonnées.



Inertie

L'**inertie**, également appelée somme des carrés intra-cluster (WCSS - Within-Cluster Sum of Squares), quantifie la compacité des clusters.

Une faible inertie indique des clusters denses et bien définis, où les points sont proches de leur centroïde respectif.




Algorithme K-Means

Fonctionnement

Algorithme de clustering qui partitionne n observations en k clusters, où chaque observation appartient au cluster dont le centroïde est le plus proche.

Étapes de l'algorithme

- 1 Initialisation**
Choisir aléatoirement k centroïdes initiaux
- 2 Affectation**
Chaque point de données est affecté au cluster dont le centroïde est le plus proche
- 3 Mise à jour**
Les centroïdes sont recalculés comme la moyenne des points assignés
- 4 Itération**
Répéter jusqu'à convergence



Avantages

- ✓ Simplicité et rapidité
- ✓ Efficacité sur grands ensembles

Limitations

- ⚠ Nécessité de choisir k à l'avance
- ⚠ Sensibilité aux centroïdes initiaux
- ⚠ Formes de clusters sphériques

Clustering Hiérarchique



Approche Agglomérative (bottom-up)

- Chaque point de données commence comme son propre cluster
- Les clusters les plus proches sont fusionnés itérativement
- La "proximité" entre clusters est définie par une méthode de liaison
- On s'arrête quand un seul cluster englobe tous les points ou qu'une condition d'arrêt est remplie



Approche Divisive (top-down)

- Tous les points de données commencent dans un seul cluster
- Le cluster est divisé récursivement en sous-clusters plus petits
- Chaque division respecte une condition d'arrêt
- Le processus se termine quand chaque point de données est dans son propre cluster

Dendrogramme : Visualisation des hiérarchies




Représentation arborescente qui visualise la séquence de fusions ou de divisions des clusters



L'axe vertical représente la distance ou la dissimilarité à laquelle les clusters sont fusionnés (ou divisés)



L'axe horizontal représente les points de données individuels ou les clusters



En coupant le dendrogramme à une certaine hauteur, on obtient un partitionnement des données en un nombre spécifique de clusters

Algorithme DBSCAN

Approche basée sur la densité


DBSCAN (Density-Based Spatial Clustering of Applications with Noise) regroupe les points en fonction de leur densité. Il ne nécessite pas de spécifier le nombre de clusters à l'avance et peut découvrir des clusters de formes arbitraires.

Types de points

-  **Points de cœur** : Dans un rayon ϵ , ils contiennent au moins MinPts points
-  **Points de bordure** : Dans le rayon ϵ d'un point de cœur, mais ils-mêmes pas de cœur
-  **Points de bruit** : Ni de cœur ni de bordure

Avantages

-  Détecte des clusters de formes arbitraires
-  Identifie les points de bruit (outliers)
-  Efficace pour des densités variables




Réduction de Dimension et PCA



Objectifs de la réduction de dimension

- Contrairement au "fléau de la dimensionnalité" qui rend les modèles plus complexes et sujets au surapprentissage
- Simplifier le modèle et améliorer ses performances
- Faciliter la visualisation des données
- Permettre une meilleure interprétation des structures sous-jacentes



Principes fondamentaux de la PCA

L'Analyse en Composantes Principales (PCA) est une technique de réduction de dimension linéaire qui transforme des variables corrélées en variables non corrélées appelées composantes principales.

1

Standardisation des données

Les données sont centrées et réduites (moyenne à zéro, écart-type à un)

2

Calcul de la matrice de covariance

Mesure la covariance entre toutes les paires de caractéristiques

3

Calcul des vecteurs propres et valeurs propres

Les vecteurs propres représentent les axes principaux de variance

4

Sélection des composantes principales

Tri des vecteurs propres par ordre décroissant de leurs valeurs propres

5

Projection des données

Projection des données sur le sous-espace défini par les composantes principales

Visualisation des Clusters




Techniques de Visualisation

La visualisation est cruciale pour comprendre et valider les résultats du clustering.


Données 2D

Nuage de points avec chaque axe représentant une caractéristique.



Données 3D

Visualisation 3D avec trois axes, moins lisible mais plus informative.



Données >3D

Réduction de dimension (PCA) pour projeter les données dans un espace 2D/3D.



Interprétation des Résultats



Coloration par cluster : Chaque point est coloré selon son cluster attribué.



Visualisation des centroïdes : Représentation des centres des clusters.



Représentation des dendrogrammes pour le clustering hiérarchique.



Éboulis des valeurs propres pour la PCA afin de choisir le nombre de composantes.



Bons Principes



Simplicité

Préférez les visualisations simples aux complexes.



Interprétabilité

Assurez-vous que la visualisation soit interprétable.



Information

Conservez l'information essentielle de la visualisation.



Validité

Validez les résultats avec des méthodes statistiques.

Interprétation de la PCA



Choix du nombre de composantes

- Graphique des éboulis des valeurs propres (scree plot)
- Rechercher un "coude" dans la courbe
- Retenir un nombre de composantes expliquant 80-90% de la variance totale



Analyse des chargements

Les chargements relient les variables originales aux composantes principales.

- Ils indiquent l'importance et la direction de la contribution
- Exemple : composante principale avec chargements élevés pour "taille" et "poids" → dimension liée à la corpulence




Interprétation des composantes

Chaque composante principale est une nouvelle variable synthétique qui capture une dimension de la variabilité des données.

- Examiner les variables originales avec la contribution la plus élevée
- Donner un sens à ces nouvelles dimensions

Exemple de graphique des éboulis



Procédure d'interprétation

- 1 Déterminer le nombre optimal de composantes via le graphique des éboulis
- 2 Analyser les chargements des variables originales sur chaque composante
- 3 Visualiser les données projetées sur les composantes principales
- 4 Donner un sens à chaque composante principale en fonction des variables qui y contribuent le plus

Synthèse et Applications Pratiques



Méthodes Résumées

Clustering

- K-Means : Partitionnement autour de centroïdes
- Clustering Hiérarchique : Dendrogrammes et regroupements hiérarchiques
- DBSCAN : Base sur la densité, capable de découvrir formes arbitraires

Réduction de Dimension

- PCA : Analyse en Composantes Principales pour transformer les données
- Identification des axes de variance maximale
- Simplification de la représentation tout en préservant l'information

Valeurs Clés

 Exploration de données

 Découverte de motifs

 Amélioration des performances

Applications Pratiques



Data Science

Préparation et exploration de données avant l'analyse approfondie



Marketing

Segmentation de clients et découverte de comportements d'achat



Bioinformatique

Analyse de séquences et clustering de gènes similaires



Détection d'anomalies

Identification de valeurs aberrantes dans les données

"L'apprentissage non supervisé transforme les données brutes en informations exploitables, offrant une compréhension approfondie des ensembles de données complexes."