

Data Science & Machine Learning

Presentation du module

Pourquoi ce module ?

La **Data Science** consiste à transformer des données en connaissances utiles pour :

- Comprendre un phénomène
- Répondre à une question
- Aider à prendre une décision

Le **Machine Learning** permet d'aller plus loin en construisant des modèles capables de :

-  **Prédire** une valeur ou une catégorie à partir d'exemples connus.
-  **Identifier** des groupes ou des structures qui ne sont pas connus à l'avance.

 **Objectif principal** : Apprendre à passer d'un jeu de données à une **analyse argumentée** : comprendre, préparer, choisir une méthode adaptée, évaluer les résultats et en identifier les limites.

Les objectifs du module

À l'issue du module, vous devrez être capables de :

-  Comprendre et explorer un jeu de données
 -  Identifier les problèmes de qualité des données
 -  Préparer les données pour leur analyse
 -  Formuler une problématique de Machine Learning
 -  Distinguer apprentissage supervisé et non supervisé
 -  Construire et évaluer un premier modèle prédictif
 -  Réaliser une segmentation par clustering
 -  Interpréter les résultats obtenus
 -  Porter un regard critique sur un modèle et ses limites
-

Environnement de travail

Les travaux pratiques seront principalement réalisés avec l'écosystème Python Data Science :

-  Google Colab
-  Python
-  Pandas
-  Matplotlib / Seaborn
-  Scikit-learn

! L'objectif n'est pas de devenir expert de chacune de ces bibliothèques, mais de savoir les mobiliser dans une **démarche cohérente** de Data Science.

Notre parcours en 6 séances

Séance	Date	Question	Principales notions
1	16/09 <i>matin</i>	Comment comprendre mes données ?	Data Science & ML, démarche KDD / CRISP-DM / SEMMA, import, inspection, qualité, valeurs manquantes, distributions, outliers, EDA
2	16/09 <i>ap.midi</i>	Peut-on prédire quelque chose ?	Apprentissage supervisé, X et y, train/test, encodage, standardisation, pipeline, régression, premières métriques
3	24/09 <i>matin</i>	Mon modèle est-il réellement bon ?	Généralisation, baseline, métriques, train/test, underfitting, overfitting, biais/variance, data leakage, interprétation
4	24/09 <i>ap.midi</i>	Peut-on découvrir des groupes dans les données ?	Apprentissage non supervisé, clustering, K-Means, distances, standardisation, choix de K, coude, silhouette, interprétation
5	27/10 <i>matin</i>	Que racontent finalement mes données ?	Projet fil rouge : consolidation, choix méthodologiques, visualisations, interprétation, limites et préparation de la restitution
6	27/10 <i>ap.midi</i>	Suis-je capable de défendre mon analyse ?	Évaluation : restitution du projet, justification de la démarche et des choix, interprétation des résultats et questions

① JE COMPRENDS → EDA & qualité des données

② JE PRÉDIS → Apprentissage supervisé

③ J'ÉVALUE → Performance & généralisation

④ JE SEGMENTE → Apprentissage non supervisé

⑤ J'INTERPRÈTE → Projet fil rouge

⑥ JE DÉFENDS → Évaluation

Le projet fil rouge : Data Science pour la transition écologique

Tout au long du module, vous travaillerez **en groupe** sur un même jeu de données lié à un enjeu environnemental.

Vous pourrez partir :

- 📁 D'un des jeux de données proposés dans le catalogue ;
- 🔍 Ou d'un autre jeu de données que vous aurez identifié (*sous réserve de validation*).

Votre mission à partir de données réelles :

1. **COMPRENDRE** — Contenu, qualité et phénomènes observés ?
 2. **PRÉDIRE** — Variable à prédire ? Informations nécessaires ? Performances ?
 3. **SEGMENTER** — Profils ou groupes émergents non connus d'avance ?
 4. **INTERPRÉTER** — Apports réels, exploitabilité et limites des résultats ?
-

Attention sur le Projet Fil Rouge

- 🎯 **La démarche prime sur le score** : Le but n'est pas d'obtenir à tout prix un excellent score. Un modèle peu performant mais correctement construit et dont les limites sont comprises vaut mieux qu'un modèle performant inexplicé.

-  **Donner du sens au Clustering** : Un clustering ne révèle pas automatiquement des groupes « vrais ». Vous devrez donner du sens aux groupes obtenus et justifier leur intérêt métier/pratique.

Le fil rouge au fil des séances

Étape	Travail sur votre projet
S1 – Explorer	Découverte du dataset, EDA, qualité, valeurs manquantes, premières visualisations et hypothèses
S2 – Prédire	Choix d'une problématique supervisée, définition de X et y, préparation et premier modèle
S3 – Évaluer	Baseline, performances, généralisation, diagnostic du modèle, limites et pistes d'amélioration
S4 – Segmenter	Sélection des variables, standardisation, K-Means, choix de K et interprétation des clusters
S5 – Consolider	Finalisation de l'analyse, visualisations, conclusions, limites et préparation de la restitution
S6 – Restituer	Présentation et défense de la démarche et des résultats

Comment serez-vous évalués ?

L'évaluation repose sur deux temps forts :

Évaluation 1 – Apprentissage supervisé

Présenter et justifier votre démarche prédictive :

Problématique → Préparation → Modèle → Évaluation → Interprétation
→ Limites

(La performance brute n'est pas le seul critère : la pertinence et la justification sont essentielles)

Comment serez-vous évalués ? (Suite)

Évaluation 2 – Apprentissage non supervisé & Synthèse du projet

Présentation de votre travail de segmentation lors de la dernière séance :

Également évalué : Votre capacité à **prendre du recul** sur l'ensemble du projet fil rouge et à **répondre aux questions** concernant vos choix.

Catalogue de données pour votre projet

Déchets et recyclage

- Collecte, traitement, recyclage ou valorisation des déchets ménagers.
- *Exemples* : Profils de territoires ? Anticipation des volumes de déchets ?

Énergie et bâtiments

- Diagnostics de performance énergétique (DPE), caractéristiques et consommations des logements.
- *Exemples* : Facteurs associés à la consommation ? Profils de bâtiments ?

Mobilité et environnement

- Caractéristiques techniques, consommations et émissions des véhicules.
 - *Exemples* : Estimation des émissions ? Profils de véhicules ?
-

Catalogue de données (Suite)

Qualité environnementale des territoires

- Qualité de l'air, qualité de l'eau, exposition au radon, caractéristiques territoriales.
- *Exemples* : Profils environnementaux des communes ? Facteurs explicatifs des indicateurs ?

Alimentation et empreinte environnementale

- Impact environnemental de produits alimentaires (ex: Agribalyse).
 - *Exemples* : Facteurs impactant l'empreinte ? Familles de produits selon leur profil écologique ?
-

À vous de transformer des données en problématique ! 🔥

- 💡 Les questions proposées sont des **exemples** et non des sujets imposés.
- 🎯 Votre première mission : examiner votre jeu de données et déterminer :

« Qu'est-ce que ces données permettent réellement d'étudier ? »

📌 *En Data Science, la question doit toujours être compatible avec les données disponibles.*