

ÉVALUATION FINALE

Module : Data Science & Machine Learning

Projet Fil Rouge – Analyse complète d'un jeu de données

- Analyse exploratoire (EDA)
- Apprentissage supervisé
- Évaluation et généralisation
- Apprentissage non supervisé (clustering)
- Interprétation métier
- Analyse critique

Il ne s'agit pas d'obtenir le meilleur score,
mais de démontrer une **démarche rigoureuse et argumentée**.



Travail demandé

Vous devez travailler sur **votre jeu de données fil rouge**.

Votre projet devra comporter deux parties :

PARTIE A – Analyse supervisée (Prédiction)



Définition du problème

Vous devez :

- Définir clairement une variable cible (Y)
- Justifier son choix d'un point de vue métier
- Formuler la problématique de prédiction

2 Préparation des données

- Nettoyage si nécessaire
- Sélection des variables
- Encodage / scaling si requis
- Séparation train / test

3 Baseline

Vous devez construire une baseline pertinente :

- Régression : moyenne
- Classification : classe majoritaire

Et comparer votre modèle à cette baseline.

4 Modélisation

Vous devez tester **au minimum deux modèles supervisés différents**.

Exemples :

- Régression linéaire
- Arbre de décision
- Random Forest
- KNN
- Logistic Regression (si classification)

5 Évaluation

Vous devez :

- Utiliser une métrique adaptée (R^2 , RMSE, F1, etc.)
- Comparer train vs test
- Effectuer une validation croisée
- Analyser biais / variance

6 Interprétation

Vous devez discuter :

- Les performances sont-elles satisfaisantes ?
- Le modèle bat-il la baseline ?
- Les résultats sont-ils stables ?
- Les variables sont-elles pertinentes ?

PARTIE B – Analyse non supervisée (Clustering)

1 Objectif

Segmenter votre dataset pour en comprendre la structure interne.

2 Préparation

- Sélectionner des variables pertinentes
- Justifier votre choix
- Standardiser les données

3 Détermination du nombre de clusters

Vous devez :

- Tester plusieurs valeurs de K
- Tracer la méthode du coude
- Calculer le score silhouette
- Justifier le choix final

Analyse des clusters

- Décrire le profil moyen de chaque cluster
- Interpréter les différences
- Discuter l'intérêt métier de cette segmentation

PARTIE C – Discussion critique globale

Vous devez répondre à :

- Le supervisé apporte-t-il une valeur ?
- Le non supervisé apporte-t-il une lecture complémentaire ?
- Quelles sont les limites de votre dataset ?
- Faut-il plus de données ?
- Faut-il enrichir les variables ?
- Quels axes d'amélioration proposeriez-vous ?



Livrables attendus

-  Notebook propre, commenté et structuré
-  Slides de synthèse (5 à 8 diapositives maximum)
-  Soutenance orale (10–12 minutes)



Structure imposée de la soutenance

1. Présentation du problème métier
2. Description du dataset
3. Analyse supervisée
4. Analyse non supervisée
5. Diagnostic global
6. Limites et recommandations