Data Science & Machine Learning

Évaluation Finale — Apprentissage non supervisé & Restitution du projet fil rouge

Travail en Groupe | **Matin : Préparation** | **Après-midi : Restitution**

🎯 OBJECTIF GÉNÉRAL DE L'ÉVALUATION

À partir du jeu de données utilisé tout au long du module, vous devez présenter votre démarche globale de Data Science et démontrer votre capacité à identifier, analyser et interpréter des groupes d'observations à l'aide de méthodes d'apprentissage non supervisé.

L'évaluation portera principalement sur la **pertinence de votre segmentation**, la **justification de vos choix méthodologiques**, l'**interprétation des résultats** et votre **capacité de prise de recul**.

PARTIE 1 — EXPLORER : COMPRENDRE LES DONNÉES ET DÉFINIR LES ENJEUX

Présentez de manière synthétique le contexte global et la structure de vos données :

- Le **thème** et la **problématique environnementale** étudiée.
- L'**origine**, la **structure** et les principales caractéristiques du jeu de données.
- Les principaux enseignements issus de votre exploration initiale (EDA).
- Les **limites ou difficultés** rencontrées concernant la qualité des données (valeurs manquantes, aberrantes, bruits).

> **QUESTION CENTRALE — PARTIE 1**
> *Que nous apprennent ces données sur le phénomène environnemental étudié ?*

💡 MÉMO PÉDAGOGIQUE — EDA (EXPLORATORY DATA ANALYSIS)

L'**EDA** consiste à analyser les jeux de données pour en résumer les caractéristiques principales, souvent avec des méthodes visuelles. Elle permet d'identifier les distributions (histogrammes, boxplots), d'évaluer la colinéarité entre variables (matrice de corrélation) et de détecter les valeurs aberrantes (outliers) avant toute modélisation.

PARTIE 2 — PRÉDIRE : BILAN SYNTHÉTIQUE DE L'APPRENTISSAGE SUPERVISÉ

Dressez un résumé concis de la phase supervisée menée précédemment (déjà évaluée) :

- La **problématique de prédiction** retenue et la variable cible y.
- Les principales variables explicatives X sélectionnées.
- Les **modèles testés** et les **résultats obtenus** (métriques de performance).
- Votre conclusion synthétique sur l'intérêt et les limites du modèle retenu.

> **QUESTION CENTRALE — PARTIE 2**
> *Votre approche supervisée a-t-elle permis de répondre à votre problématique initiale ?*

PARTIE 3 — SEGMENTER : CONSTRUIRE ET INTERPRÉTER DES GROUPES

Cette partie constitue le cœur de votre évaluation d'aujourd'hui.

Vous devez réaliser une segmentation de votre jeu de données à l'aide d'une méthode d'apprentissage non supervisé.

Travail obligatoire (K-Means)

1. **Définir l'objectif :** Quelles observations souhaitez-vous regrouper et pourquoi ?
2. **Sélection des variables :** Sélectionner les variables pertinentes et justifier rigoureusement vos choix.
3. **Prétraitements :** Expliquer les prétraitements réalisés, notamment la standardisation (scaling).
4. **Modélisation K-Means :** Appliquer l'algorithme et tester plusieurs nombres de clusters (*K*).
5. **Choix de K :** Présenter la méthode du coude et le score de silhouette, puis justifier le choix retenu.
6. **Caractérisation :** Présenter les profils obtenus (effectifs, moyennes, caractéristiques distinctives).
7. **Interprétation métier :** Donner du sens aux clusters en lien avec la problématique environnementale.
8. **Visualisation :** Représenter les résultats à l'aide de graphiques adaptés (éventuellement via ACP/PCA).

💡 MÉMO — STANDARDISATION & K-MEANS

Standardisation (StandardScaler) : Transforme les données pour obtenir une moyenne de 0 et un écart-type de 1 ($z = (x - \mu) / \sigma$). Essentielle pour K-Means car l'algorithme calcule des distances euclidiennes : sans standardisation, les variables à forte échelle dominent le calcul.

Algorithme K-Means : Regroupe les données en *K* clusters en minimisant l'inertie intra-classe (somme des distances au carré entre chaque point et le centre de son cluster).

📐 MÉTHODE DU COUDE (ELBOW METHOD)

Technique graphique traçant l'**inertie intra-classe** globale en fonction de *K*. Le choix optimal correspond au point d'inflexion ("coude"), où l'ajout d'un cluster supplémentaire n'apporte plus d'amélioration significative de la cohérence.

📊 SCORE DE SILHOUETTE

Mesure à quel point un point est similaire à son propre cluster comparé aux autres (de -1 à +1). Un score proche de 1 indique un bon regroupement bien séparé. La moyenne globale guide la sélection de *K*.

🗺️ VISUALISATION ACP / PCA (ANALYSE EN COMPOSANTES PRINCIPALES)

Méthode de réduction de dimension qui projette un espace à multiples variables sur 2 ou 3 axes synthétiques (composantes principales) en conservant au maximum la variance. Utile pour visualiser sur un plan 2D des clusters formés sur des dizaines de dimensions.

Approfondissement facultatif (Méthodes complémentaires)

Vous pouvez expérimenter une autre méthode de clustering et comparer ses résultats avec K-Means :

- **DBSCAN :** Pour explorer une segmentation basée sur la densité d'observations.
- **Clustering Hiérarchique (CAH) :** Pour analyser l'organisation des données sous forme d'arbre (dendrogramme).

> 💡 **MÉMO — DBSCAN VS CAH (APPROFONDISSEMENT)**
>
> **DBSCAN :** Ne nécessite pas d'imposer *K*. Identifie les zones de haute densité et classe les points isolés comme du bruit/outliers. Idéal pour des formes complexes non sphériques.
>
> **Clustering Hiérarchique (CAH) :** Construit une hiérarchie de partitions illustrée par un dendrogramme, permettant de choisir le niveau de regroupement visuellement sans réentraîner l'algorithme.

> **QUESTION CENTRALE — PARTIE 3**
> *Les clusters identifiés révèlent-ils des profils cohérents, interprétables et utiles pour la décision ?*

PARTIE 4 — ANALYSER : PRISE DE RECUL ET PERSPECTIVES

Présentez une conclusion critique et argumentée sur l'ensemble de votre démarche :

- Quels sont les **principaux enseignements** de votre analyse non supervisée ?
- Vos clusters correspondent-ils à des groupes **réellement distincts** ou à un découpage artificiel ?
- Quelles **limites** identifiez-vous (qualité des données, algorithmes, variables manquantes) ?
- Quelles pistes d'amélioration (nouvelles variables, autres méthodes) proposez-vous ?
- En quoi vos résultats sont-ils valorisables dans un cadre environnemental ou professionnel ?

> **QUESTION CENTRALE — PARTIE 4**
> *Que peut-on raisonnablement conclure de vos résultats, et que ne peut-on pas conclure ?*

LIVRABLES ET RESTITUTION DE L'APRÈS-MIDI

Chaque groupe devra présenter publiquement sa démarche et fournir :

- **Un support de restitution :** Synthétique, visuel et clairement structuré (slides/présentation).
- **Un Notebook Python :** Propre, commenté, contenant les prétraitements, modèles et graphiques.
- **Une conclusion orale argumentée :** Mettant en valeur la pertinence et les limites.

> ⚠️ **Remarque importante pour l'évaluation :**
> La valeur de votre travail ne dépend pas uniquement des métriques ou des scores obtenus. Un clustering présentant des limites mais **correctement construit, interprété et discuté de façon critique** peut constituer un excellent travail. L'objectif est d'expliquer ce que vous avez fait, pourquoi vous l'avez fait et ce que cela signifie.